

实验四 BP 神经网络实验


一、实验目的

- 4、熟悉神经网络的基本概念和原理；
- 5、可以通过在 Anaconda，MATLAB 等工具下编程实现神经网络构建算法，了解基本认识
- 6、使用自己的数据集，运用线性模型进行数据分析，解决实际问题。


二、实验原理

由于传统的感知器和线性神经网络有自身无法克服的缺陷，它们都不能解决线性不可分问题，因此在实际应用过程中受到了限制。而 BP 网络却拥有良好的繁泛化能力、容错能力以及非线性映射能力。因此成为应用最为广泛的一种神经网络。

BP 算法的基本思想是把学习过程分为两个阶段：第一阶段是信号的正向传播过程；输入信息通过输入层、隐层逐层处理并计算每个单元的实际输出值；第二阶段是误差的反向传递过程；若在输入层未能得到期望的输出值，则逐层递归的计算实际输出和期望输出的差值（即误差），以便根据此差值调节权值。这种过程不断迭代，最后使得信号误差达到允许或规定的范围之内。



基于 BP 算法的多层前馈型网络模型的拓扑结构如上图所示。



BP 算法的数学描述：三层 BP 前馈网络的数学模型如上图所示。三层前馈网中，输入向量为： $X = (x_1, x_2, \dots, x_i, \dots, x_n)^T$ ；隐层输入向量为： $Y = (y_1, y_2, \dots, y_j, \dots, y_m)^T$ ；输出层输出向量为： $O = (o_1, o_2, \dots, o_k, \dots, o_l)^T$ ；期望输出向量为： $d = (d_1, d_2, \dots, d_k, \dots, d_l)^T$ 。输入层到隐层之间的权值矩阵用 V 表示， $V = (v_1, v_2, \dots, v_j, \dots, v_m)^Y$ ，其中列向量 v_j 为隐层第 j 个神经元对应的权向量；隐层到输出层之间的权值矩阵用 W 表示， $W = (w_1, w_2, \dots, w_k, \dots, w_l)$ ，其中列向量 w_k 为输出层第 k 个神经元对应的权向量。

下面分析各层信号之间的数学关系。

对于输出层，有

$$y_j = f(\text{net}_j), j = 1, 2, \dots, m$$

$$\text{net}_j = \sum v_{ij} x_i, j = 1, 2, \dots, m$$

对于隐层，有

$$O_k = f(\text{net}_k), k = 1, 2, \dots, l$$

$$\text{net}_k = \sum_{j=0}^m w_{jk} y_j, k = 1, 2, \dots, l$$

以上两式中，转移函数 $f(x)$ 均为单极性 Sigmoid 函数： $f(x) = \frac{1}{1 + e^{-x}}$

$f(x)$ 具有连续、可导的特点，且有 $f'(x) = f(x)[1 - f(x)]$

以上共同构成了三层前馈网了的数学模型。

当网络输出和期望输出不相等时，存在输出误差 E 如下：

$$E = \frac{1}{2}(d - o)^2 = \frac{1}{2} \sum_{j=0}^m (d_k - o_k)^2$$

将以上误差定义式展开至隐层，有

$$E = \frac{1}{2} \sum_{k=1}^l [d_k - f(\text{net}_j)]^2 = \frac{1}{2} \sum_{k=1}^l [d_k - f(\sum_{j=0}^m w_{jk} y_j)]^2$$

进一步展开至输入层，有

$$E = \frac{1}{2} \sum_{k=1}^l \{d_k - f[\sum_{j=0}^m w_{jk} f(\text{net}_j)]\}^2 = \frac{1}{2} \sum_{k=1}^l \{d_k - f[\sum_{i=0}^n w_{jk} f(\sum_{i=0}^n v_{ij} x_i)]\}^2$$

由上式可以看出，网络输入误差是两层权值 W 和 V 的函数，因此调整权值可以改变误差 E。

显然，调整权值的原则是使误差不断的减小，因此应使权值的调整量与误差的负梯度成正比，即：

$$\Delta w_{jk} = -\eta \frac{\partial E}{\partial w_{jk}}, j = 0, 1, 2, \dots, m; k = 1, 2, \dots, l$$

$$\Delta v_{ij} = -\eta \frac{\partial E}{\partial v_{ij}}, i = 0, 1, 2, \dots, n; j = 1, 2, \dots, m$$


式中负号表示梯度下降，常数 $\eta \in (0, 1)$ 表示比例系数，在训练中反映了学习速率。

容易看出，BP 学习算法中，各层权值调整公式形式上都是一样的，均有 3 个因素决定，即：学习速率、本层误差信号和本层输入信号 X/Y。其中输出层误差信号同网络的期望输出与实际输出之差有关，直接反映了输出误差，而各隐层的误差信号与前面各层的误差信号都有关，是从输出层开始逐层反传过来的。

三、程序代码参考

```
clc
clear all
k=1;
n=10;
P=[-1:0.05:1];
T=sin(k*pi*P);
```

```
plot(P,T,'-');
title('要逼近的非线性函数');
xlabel('输入向量');
ylabel('非线性函数目标输出向量');
net=newff(minmax(P),[n,1],{'tansig','purelin'},'trainlm');
y1=sim(net,P);
net.trainParam.epochs=50;
net.trainParam.goal=0.01;
net=train(net,P,T);
y2=sim(net,P);
figure;
plot(P,T,'-',P,y1,'--',P,y2,'*');
title('训练前后的网络仿真结果对比');
xlabel('输入向量');
ylabel('输出向量');
legend('目标函数输出向量','未训练 BP 网络输出','已训练 BP 网络输出');
仿真结果（参考）:
```



由仿真结果图可以看出，未经训练的 BP 网络输出与目标函数差距很大，逼近效果不理想，而对 BP 网络训练之后的输出可以较精确的逼近目标函数，并且 BP 网络的训练迭代次数仅约 1.2 次，网络的输出目标误差就达到了精度要求，收敛速度很快。函数逼近效果、网络训练的收敛速度与原始非线性函数的频率、BP 网络隐含层单元神经元的数目以及 BP 网络训练函数有关。

四、实验结论分析

通过编程实现使用 BP 网络对函数进行逼近，对 BP 网络的信号和误差传递的原理以及隐层、输出层权值调整的规则有了充分的理解和认识。

同学自行选择数据集，根据实验过程构建方法，加深对算法的理解和实践，并提交实验报告。

