


机器学习

MACHINE LEARNING





机器学习

- 课程介绍
 - 教材及参考书
 - 上课主要内容
 - 课程目的与要求
 - 考核方式

教材及参考书

■ 教材

- 《机器学习》周志华 著，清华大学出版社，2016.



教材及参考书

■ 参考资料


- 《机器学习》(美)米歇尔(Mitchell, T. M.)著, 机械工业出版社, 2008.
- 论文文献





课程主要内容

- 基本概念
- 模型评估与选择
- 线性模型
- 决策树
- 神经网络
- 支持向量机
- 贝叶斯分类
- 集成学习
- 聚类



课程目的与要求

■ 目的

- 讲解机器学习的研究对象、基本研究方法、学习范型、核心算法、理论以及应用技术
- 使学生掌握常见机器学习的基本理论和主要方法，掌握在大量的模式样本中获取有用信息的原理和算法，包括算法的主要思想和基本步骤
- 通过编程练习和典型应用实例加深理解，为学生在该领域的进一步研究和工程应用奠定基础




课程目的与要求

■ 要求

- 掌握机器学习的基本概念、基本理论和主要方法
- 学会处理应用机器学习解决实际中遇到的各类问题
- 提高开展科研工作和工程实践的能力以及独立思考、分析、解决问题的能力


■ 先修课程

- 数学分析、概率论与数理统计、面向对象语言编程、数据结构与算法




考核方式

- 理论考试成绩60%+实验成绩30%+平时成绩10%
 - 理论考试成绩
 - 闭卷
 - 基本概念、基本理论、主要方法
 - 实验和平时成绩
 - 实验+报告（独立完成）
 - 到课出勤和课堂讨论




第1章 绪论



主要内容

- 基本术语
- 假设空间
- 归纳偏好
- 发展历程
- 应用现状



1.1 引言

- 人能做出有效的预判，是因为已经积累了许多经验，通过对经验的利用，就能对新情况做出有效的决策
- （计算机能替代吗）机器学习致力于研究如何通过计算的手段，利用经验来改善系统自身的性能
 - 在计算机系统中，经验通常以数据形式存在
 - 机器学习研究的主要内容是如何在计算机上从数据中产生模型，即学习算法
 - 在面对新的数据时，模型会提供相应的判断
 - 模型和模式
 - 模型泛指从数据中学得的结果，是全局性结果。模式指局部性结果，如一条规则

1.2 基本术语

■ 数据集

- 一组数据记录的集合, $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$

■ 样本(示例)

- 一条记录, 是关于一个事件或对象的描述, $\mathbf{x}_i$

■ 特征(属性)

- 反映事件或对象在某方面的表现或性质的事项, $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{id})$

■ 样本的维数

- 样本特征的个数, d

■ 特征值(属性值)

- 属性上的取值, x_{ij}

1.2 基本术语

- 特征空间 (属性空间, 样本空间, 输入空间)
 - 属性张成的空间, $\mathbf{x}_i \in X$
 - 样本空间中全体样本服从一个未知分布 D
- 特征向量 $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{id})$
 - 特征空间中的点 (示例) 对应的坐标向量
- 训练 (学习)
 - 从数据中学得模型的过程, 通过学习算法完成
- 训练数据
 - 训练过程中使用的数据
- 训练样本
 - 训练数据中的每个样本
- 训练集
 - 训练样本组成的集合

1.2 基本术语

- 假设(模式)

- 学习得到的模型 f 对应数据的某种潜在规律

- 真相(真实)

- 潜在规律自身

- 标记(标签)

- 关于示例(样本)结果的信息, y_i

- 标记空间(输出空间)

- 所有标记的集合, $Y, y_i \in Y$


- 样例

- 拥有了标记信息的示例(样本), (x_i, y_i)

- 训练(学习)

- 建立一个从输入空间 X 到输出空间 Y 的映射

$$f: X \rightarrow Y$$



1.2 基本术语

■ 分类

- 预测的是离散值(标记)

- 二分类

- 只涉及两个类别, $Y = \{0,1\}$

- 正类

- 反类

- 多分类

- 涉及多个类别, $|Y| > 2$

■ 回归


- 预测的是连续值(标记), $Y = R$

■ 测试

- 使用模型进行预测的过程

■ 测试样本

- 被预测的样本, 预测标记 $y = f(\mathbf{x})$



1.2 基本术语

■ 聚类

- 学习过程中使用的训练样本不拥有标记信息
- 概念事先是不知道
- 将训练集中的样本自动分成若干组，每组称为一个“簇”，对应一些潜在的概念划分

■ 监督学习、无监督学习


- 根据训练数据是否拥有标记信息

■ 泛化能力

- 学得模型适用于新样本的能力
- 机器学习的目标是使学得模型能很好地适用于“新样本”
- 具有强泛化能力的模型能很好适用整个样本空间


1.2 基本术语

- 监督学习(supervised learning)
- 无监督学习(unsupervised learning)



- 数据集; 训练, 测试
- 示例(instance), 样例(example)
- 样本(sample)
- 属性(attribute), 特征(feature); 属性值
- 属性空间, 样本空间, 输入空间
- 特征向量(feature vector)
- 标记空间, 输出空间

- 未见样本(unseen instance)
- 未知“分布”
- 独立同分布(i.i.d.)
- 泛化(**generalization**)



1.3 假设空间

- 演绎与归纳是科学推理的两大基本手段
 - 一般 → 特殊，特化，演绎
 - 特殊 → 一般，泛化，归纳
 - 从样例中学习亦称归纳学习
 - 广义，从样例中学习
 - 狭义，从训练数据中学得概念，概念学习(形成)
 - 概念学习技术目前研究和应用都比较少，因为要学得泛化性能好且语义明确的概念太困难
 - 现实常用的技术大多是产生黑箱模型

1.3 假设空间

- 学习过程可看成在所有假设(概念、模式)组成的空间中进行搜索的过程
 - 假设空间
 - 由特征的可能取值所形成的假设组成
 - 假设的表示一旦确定, 假设空间及其规模大小就确定了
 - 搜索目标是找到与训练集匹配的假设, 即能够将训练集中的示例判断正确的假设
 - 可以有許多策略对假设空间进行搜索
 - 自顶向下、从一般到特殊
 - 自底向上、从特殊到一般
 - 搜索过程中可以不断删除与正例不一致的假设、和与反例一致的假设
 - 最终获得与训练集一致, 即对所有训练样本能够进行正确判断的假设, 这就是学得的结果


1.3 假设空间


■ 版本空间

- 学习过程是基于有限样本训练集进行的，可能有多个假设与训练集一致，即存在着一个与训练集一致的假设集合，称为版本空间

■ 问题

- 在面对新样本时，不同的假设(模型)会产生不同的输出
- 应该采用哪一个模型(假设)





1.4 归纳偏好


■ 归纳偏好

- 对于一个具体的学习算法而言，它必须要产生一个模型
 - 随机选择
 - 学得模型时而判断是好的、时而判断是不好的，这样的学习结果没有意义
 - 基于偏好
- 机器学习算法在学习过程中对某种类型假设的偏好，称为归纳偏好

1.4 归纳偏好

归纳偏好

- 如何确立正确(更好)的假设(模型)
 - 奥卡姆剃刀原则, 若有多个假设与观察一致, 则选最简单的那个
 - 在具体的现实问题中, 假设是否成立, 即算法的归纳偏好是否与问题本身匹配, 大多数时候直接决定了算法能否取得好的性能



1.4 归纳偏好



■ 哪种学习算法更好归纳出更好的模型

- 好的归纳偏好
- 模型的泛化能力更强

这种学习算法是否能得到最好的模型？

■ 没有免费的午餐定理(NFL定理)

- 比如一个算法 L_a 若在某些问题上比另一个算法 L_b 好，必存在另一些问题， L_b 比 L_a 好



1.4 归纳偏好

- 没有免费的午餐定理(NFL定理)
 - 假设样本空间 X 和假设空间 H 离散, 令 $P(h | X, L_a)$ 表示算法 L_a 基于训练数据 X 产生假设 h 的概率, f 表示要学的目标函数(模型), L_a 在训练集之外所有样本上的总误差

$$E_{ote}(L_a | X, f) = \sum_h \sum_{x \in X - X} P(x) \hat{u}[h(x) \neq f(x)] \mathcal{P}(h | X, L_a)$$

- $\hat{u}(\cdot)$ 指示函数, 真则取值1, 否则取值0

1.4 归纳偏好

■ 没有免费的午餐定理(NFL定理)

- 考虑二分类问题，目标函数可以为任何函数 $f: X \mapsto \{0,1\}$ ，函数空间为 $\{0,1\}^{|X|}$ ，对所有可能的 f 按均匀分布对误差求和

$$\begin{aligned}\sum_f E_{ote}(\mathcal{L}_a | X, f) &= \sum_f \sum_h \sum_{x \in \mathcal{X} - X} P(x) \mathbb{I}(h(x) \neq f(x)) P(h | X, \mathcal{L}_a) \\&= \sum_{x \in \mathcal{X} - X} P(x) \sum_h P(h | X, \mathcal{L}_a) \sum_f \mathbb{I}(h(x) \neq f(x)) \\&= \sum_{x \in \mathcal{X} - X} P(x) \sum_h P(h | X, \mathcal{L}_a) \frac{1}{2} 2^{|\mathcal{X}|} \\&= \frac{1}{2} 2^{|\mathcal{X}|} \sum_{x \in \mathcal{X} - X} P(x) \sum_h P(h | X, \mathcal{L}_a) \\&= 2^{|\mathcal{X}|-1} \sum_{x \in \mathcal{X} - X} P(x) \cdot 1\end{aligned}$$

总误差与学习算法无关
所有算法一样好

1.4 归纳偏好

■ NFL定理有一个重要前提是所有问题出现的机会相同、或所有问题同等重要

- 但实际情形并不是这样

- 很多时候只关注正在解决的问题，希望为它找到一个解决方法，并不关心该方法在别的问题甚至相似的问题上是否是好

■ 结论

- 讨论算法的相对优劣，必须要针对具体的学习问题
- 学习算法的归纳偏好是否与问题本身匹配，对算法性能会起到决定性的作用
- 脱离具体问题，谈论“什么学习算法更好”毫无意义，若考虑所有潜在的问题，则所有学习算法都一样好

1.5 发展历程

■ 机器学习源自人工智能

■ 1956年, 美国达特茅斯学院, 达特茅斯会议

- J. McCarthy等10余人
- J. M. 提出Artificial Intelligence (AI) 概念
- 标志着人工智能学科的诞生
- 萨缪尔发明了机器学习这个词
 - 在IBM公司研制了一个西洋跳棋程序
 - 1961年与当时全美第四的棋手对决获胜

■ 1956-1960s, 推理期

- 出发点: “数学家真聪明!”
- 主要成就: 自动定理证明系统
 - 西蒙与纽厄尔的 Logic Theorist 系统
- 渐渐意识到仅有逻辑推理能力是不够的



约翰 麦卡锡
(1927-2011)
“人工智能之父”
1971年图灵奖



赫伯特 西蒙
(1916-2001)
1975年图灵奖



阿伦 纽厄尔
(1927-1992)
1975年图灵奖

1.5 发展历程




爱德华 费根鲍姆
(1936-)
1994年图灵奖

- 1970s-1980s, 知识期
 - 出发点: “知识就是力量!”
 - 主要成就: 专家系统
 - 费根鲍姆等人的 DENDRAL系统
 - 渐渐发现, 总结出知识再教给系统, 实在太难
- 1990s-NOW, 学习期
 - 出发点: “让系统自己学!”
 - 主要成就: 决策树、神经网络、统计学习……
 - 机器学习成为突破知识工程瓶颈的利器
 - 人类发现自己淹没在数据的汪洋中, 对自动数据分析技术的迫切需要促进了机器学习的发展

1.6 应用现状


机器学习已经“无处不在”



生物信息学



Web搜索



入侵检测



汽车自动驾驶
(DARPA Grand Challenge)



火星机器人 (JPL)



决策助手(DARPA)

1.6 应用现状

今天的“机器学习”已经是一个广袤的学科领域

例如，这是第32届国际机器学习大会的“主题领域”


2006年，美国CMU（卡内基梅隆大学）成立“机器学习系”

- ☐ Active Learning
- ☐ Approximate Inference
- ☐ Bayesian Nonparametric Methods
- ☐ Bioinformatics
- ☐ Causal Inference
- ☐ Clustering
- ☐ Computational Social Sciences
- ☐ Cost-Sensitive Learning
- ☐ Digital Humanities
- ☐ Ensemble Methods
- ☐ Feature Selection and Dimensionality Reduction
- ☐ Finance
- ☐ Gaussian Processes
- ☐ Graphical Models
- ☐ Inductive Logic Programming and Relational Learning
- ☐ Information Retrieval
- ☐ Kernel Methods
- ☐ Large-Scale Machine Learning
- ☐ Latent Variable Models
- ☐ Learning for Games
- ☐ Learning Theory
- ☐ Manifold Learning
- ☐ Network and Graph Analysis
- ☐ Neural Networks and **Deep Learning**
- ☐ Planning and Control
- ☐ Privacy, Anonymity, and Security
- ☐ Ranking and Preference Learning
- ☐ Recommender Systems
- ☐ Reinforcement Learning
- ☐ Robotics
- ☐ Rule and Decision Tree Learning
- ☐ Semi-Supervised Learning
- ☐ Sparsity and Compressed Sensing
- ☐ Spectral Methods
- ☐ Speech Recognition
- ☐ Statistical Relational Learning
- ☐ Structured Output Prediction
- ☐ Supervised Learning
- ☐ Sustainability, Climate, and Environment
- ☐ Time-Series Analysis

经常被谈到的“深度学习”
(Deep Learning)仅是
机器学习中的一个小分支

1.6 应用现状


为了降低昂贵的成本, Tufts医学中心引入了机器学习技术



人类专家只需阅读 **50** 篇摘要, 系统的自动筛选精度就达到 **93%**
人类专家阅读 **1,000** 篇摘要, 则系统的自动筛选敏感度达到 **95%**
(人类专家以前需阅读 **33,000** 篇摘要才能获得此效果)

1.6 应用现状



例如：互联网搜索



机器学习技术正在支撑着各种搜索引擎

1.6 应用现状

例如：自动汽车驾驶（即将改变人类生活）




美国在20世纪80年代就开始研究基于机器学习的汽车自动驾驶技术

1.6 应用现状

例如：画作鉴别（艺术）

为了降低分析成本，机器学习技术被引入



Kröller Müller美术馆与Cornell等大学的学者对**82**幅梵高真迹和**6**幅赝品进行分析，自动鉴别精度达 **95%** [C. Johnson et al., IEEE-SP, 2008]


Dartmouth学院、巴黎高师的学者对**8**幅勃鲁盖尔真迹和**5**幅赝品进行分析，自动鉴别精度达 **100%** [J. Hughes et al., PNAS 2009][J. Mairal et al., PAMI'12]

(对用户要求低、准确高效、适用范围广)

1.6 应用现状

例如：古文献修复（文化）

以色列特拉维夫大学的学者将机器学习用于自动的书页拼接



在Cairo Genizah测试数据上，系统的自动判断精度超过 **93%**

新完成约 **1,000** 篇Cairo Genizah文章的拼接

（对比：过去整个世纪，数百人类专家只完成了几千篇文章拼接）

1.6 应用现状

例如：帮助奥巴马胜选（政治）



队长：Rayid Ghani

卡内基梅隆大学机器学习系
首任系主任Tom Mitchell
教授的博士生

通过机器学习模型：

- ◆ 在总统候选人第一次辩论后，分析出哪些选民将倒戈，为每位选民找出一个最能说服他的理由
- ◆ 精准定位不同选民群体，建议购买冷门广告时段，广告资金效率比2008年提高14%
- ◆ 向奥巴马推荐，竞选后期应当在什么地方展开活动 —— 那里有很多争取对象
- ◆ 借助模型帮助奥巴马筹集到创纪录的10亿美元

例如：利用模型分析出，明星乔治克鲁尼（George Clooney）对于年龄在40-49岁的美西地区女性颇具吸引力，而她们恰是最愿意为和克鲁尼/奥巴马共进晚餐而掏钱的人 乔治克鲁尼为奥巴马举办的竞选筹资晚宴成功募集到1500万美元




◆



1.6 应用现状

- 在各个领域
 - 航空
 - 航海
 - 电子
 - 交通
 - 经济
 -



作业
