


第4章 决策树



主要内容

- 基本流程
- 划分选择
- 剪枝处理
- 连续与缺失值
- 多变量决策树



4.0 决策树简史

- E. B. Hunt, etc' s book “Experiments in Induction”, Academic Press ,1966
 - 第一个决策树算法: CLS (Concept Learning System)
- J. R. Quinlan' s paper in a book “Expert Systems in the Micro Electronic Age”, Edinburgh University Press, 1979
 - 使决策树受到关注、成为机器学习主流技术的算法: ID3
- L. Breiman, etc' s book “Classification and Regression Trees”, Wadsworth, 1984
 - 可以用于回归任务的决策树算法: CART (Classification and Regression Tree)



4.0 决策树简史

- J. R. Quinlan' s book “C4.5: Programs for Machine Learning”, Morgan Kaufmann, 1993
 - 最常用的决策树算法: C4.5
- L. Breiman' s paper “Random Forest”, MLJ, 2001
 - 基于决策树的最强大算法: RF (Random Forest), 一种 “集成学习” 方法

4.1 基本流程

■ 决策树模型

■ 决策树基于树结构进行决策

- 一棵决策树包含一个根结点、若干个内部结点和若干个叶结点
- 每个内部结点对应于某个属性上的测试
 - 每个测试的结果或是导出最终结论，或是导出进一步的判定问题，其考虑范围是在上次决策结果的限定范围之内
- 每个分支对应于该测试的一种可能结果，即该属性的某取值
 - 每个结点包含的样本集合根据属性测试的结果被划分到子结点中
 - 根结点包含样本全集
- 每个叶结点对应于一个预测结果
 - 从根结点到每个叶结点的路径对应了一个判定测试序列

4.1 基本流程

■ 决策树模型

- 学习过程：通过对训练样本的分析来确定划分属性，即内部结点所对应的属性，从而产生一棵泛化能力强的决策树
- 预测过程：将未知示例从根结点开始，沿着划分属性所构成的判定测试序列下行，直到叶结点得到结果





图 4.1 西瓜问题的一棵决策树

4.1 基本流程

从树到规则

- 一棵决策树对应于一个规则集
- 每个从根结点到叶结点的分支路径对应于一条规则

例如



- IF (纹理=清晰) $\wedge$ (密度 ≤ 0.381) THEN 坏瓜
- IF (纹理=清晰) $\wedge$ (密度 > 0.381) THEN 好瓜
- IF (纹理=稍糊) $\wedge$ (触感=硬滑) THEN 坏瓜
- IF (纹理=稍糊) $\wedge$ (触感=软粘) THEN 好瓜
- IF (纹理=模糊) THEN 坏瓜

4.1 基本流程

■ 基本学习算法流程

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
属性集 $A = \{a_1, a_2, \dots, a_d\}$.

过程: 函数 TreeGenerate(D, A)

- 1: 生成结点 node;
- 2: **if** D 中样本全属于同一类别 C **then**
- 3: 将 node 标记为 C 类叶结点; **return**
- 4: **end if**
- 5: **if** $A = \emptyset$ **OR** D 中样本在 A 上取值相同 **then**
- 6: 将 node 标记为叶结点, 其类别标记为 D 中样本数最多的类; **return**
- 7: **end if**
- 8: 从 A 中选择最优划分属性 a_* ;
- 9: **for** a_* 的每一个值 a_*^v **do**
- 10: 为 node 生成一个分支; 令 D_v 表示 D 中在 a_* 上取值为 a_*^v 的样本子集;
- 11: **if** D_v 为空 **then**
- 12: 将分支结点标记为叶结点, 其类别标记为 D 中样本最多的类; **return**
- 13: **else**
- 14: 以 TreeGenerate($D_v, A \setminus \{a_*\}$) 为分支结点
- 15: **end if**
- 16: **end for**

输出: 以 node 为根结点的一棵决策树

4.1 基本流程

■ 基本学习算法流程

- 策略：分而治之
- 决策树的生成是一个自根至叶的递归过程
- 在每个中间结点寻找一个划分属性
- 三种递归停止条件
 - 当前结点包含的样本全属于同一类别，无需划分
 - 当前结点标记为叶结点
 - 当前属性集为空或是所有样本在所有属性上取值相同，无法划分
 - 当前结点标记为叶结点
 - 类别设定为该结点所含样本最多的类别
 - 利用当前结点的后验分布
 - 当前结点包含的样本集合为空，不能划分
 - 当前结点标记为叶结点
 - 类别设定为其父结点所含样本最多的类别
 - 将父结点的样本分布作为当前结点的先验分布

4.1 基本流程

基本学习算法流程

输入: 训练集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$;

属性集 $A = \{a_1, a_2, \dots, a_d\}$.

过程: 函数 TreeGenerate(D, A)

1: 生成结点 node;

2: if D 中样本全属于同一类别 C then

3: 将 node 标记为 C 类叶结点; return

4: end if

递归返回,
情形(1)

5: if $A = \emptyset$ OR D 中样本在 A 上取值相同 then

6: 将 node 标记为叶结点, 其类别标记为 D 中样本数最多的类; return

7: end if

递归返回,
情形(2)

8: 从 A 中选择最优划分属性 a_* ;

利用当前结点的后验分布

9: for a_* 的每一个值 a_*^v do

10: 为 node 生成一个分支; 令 D_v 表示 D 中在 a_* 上取值为 a_*^v 的样本子集;

11: if D_v 为空 then

12: 将分支结点标记为叶结点, 其类别标记为 D 中样本最多的类; return

递归返回,
情形(3)

13: else

14: 以 TreeGenerate($D_v, A \setminus \{a_*\}$) 为分支结点

将父结点的样本分布作为
当前结点的先验分布

15: end if

16: end for

决策树算法的
核心

输出: 以 node 为根结点的一棵决策树

4.2 划分选择

■ 如何选择最优划分属性

- 希望分支结点所包含的样本尽可能属于同一类别(纯度), 即结点的纯度越来越高

- 如何度量纯度

■ 4.2.1 信息增益


■ 信息熵

- 度量样本集合纯度最常用的一种指标
- 样本集D中第k类样本的比例为 p_k , 则D的信息熵

$$Ent(D) = - \sum_{k=1}^{|y|} p_k \log_2 p_k$$

- 若 $p = 0$, 则 $p \log_2 p = 0$
- $Ent(D)$ 的值越小, 则D的纯度越高

- 信息增益以信息熵为基础, 计算当前划分对信息熵造成的变化




4.2 划分选择

4.2.1 信息增益

■ 信息增益

- 设离散属性a有V个可能的取值 $\{a^1, a^2, \dots, a^V\}$
- 用a划分样本集D, 会产生V个分支结点, 第v个分支结点包含属性a取值为 a^v 的样本, 记为 D^v
- 不同分支结点所包含的样本数不同, 影响不同, 给分支结点赋予权重 $|D^v|/|D|$
- 于是可得属性a划分样本集D的信息增益

$$\text{Gain}(D, a) = \underbrace{\text{Ent}(D)}_{\text{划分前的信息熵}} - \sum_{v=1}^V \underbrace{\frac{|D^v|}{|D|}}_{\substack{\text{第 } v \text{ 个分支的权重,} \\ \text{样本越多越重要}}} \underbrace{\text{Ent}(D^v)}_{\text{划分后的信息熵}}$$



4.2 划分选择

4.2.1 信息增益

■ 信息增益

- 一般信息增益越大，使用属性a进行划分获得的纯度提升越大
- 可用信息增益进行决策树的划分属性选择，即

$$a_* = \arg \max_{a \in A} Gain(D, a)$$

- 在ID3决策树学习算法中使用

4.2 划分选择

4.2.1 信息增益

■ 信息增益

■ 例子

- 计算根结点的信息熵

该数据集包含17个
训练样例, $|Y| = 2$,
其中正例占 $p_1 = \frac{8}{17}$
反例占 $p_2 = \frac{9}{17}$

根结点的信息熵为

表 4.1 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

$$\text{Ent}(D) = - \sum_{k=1}^2 p_k \log_2 p_k = - \left(\frac{8}{17} \log_2 \frac{8}{17} + \frac{9}{17} \log_2 \frac{9}{17} \right) = 0.998$$

4.2 划分选择

4.2.1 信息增益

■ 信息增益

■ 例子

- 计算当前属性集合{色泽, 根蒂, 敲声, 纹理, 脐部, 触感}中每个属性的信息增益
 - 属性色泽对应3个数据子集, D^1 (色泽=青绿), D^2 (色泽=乌黑), D^3 (色泽=浅白)

- 子集 D^1 包含6个样例, 其中正例 $p_1 = 3/6$, 反例 $p_2 = 3/6$, D^2 、 D^3 同理, 3个结点的信息熵

$$Ent(D^1) = -(\frac{3}{6} \log_2 \frac{3}{6} + \frac{3}{6} \log_2 \frac{3}{6}) = 1.000$$

$$Ent(D^2) = -(\frac{4}{6} \log_2 \frac{4}{6} + \frac{2}{6} \log_2 \frac{2}{6}) = 0.918$$

$$Ent(D^3) = -(\frac{1}{5} \log_2 \frac{1}{5} + \frac{4}{5} \log_2 \frac{4}{5}) = 0.722$$

- 属性“色泽”的信息增益为

$$Gain(D, \text{色泽}) = Ent(D) - \sum_{v=1}^3 \frac{|D^v|}{|D|} Ent(D^v) = 0.109$$

4.2 划分选择

4.2.1 信息增益

■ 信息增益

■ 例子

- 类似可得其他属性的信息增益

$$Gain(D, \text{根蒂}) = 0.143 \quad Gain(D, \text{敲声}) = 0.141$$

$$Gain(D, \text{纹理}) = 0.381 \quad Gain(D, \text{脐部}) = 0.289$$

$$Gain(D, \text{触感}) = 0.006$$

- 属性纹理的信息增益最大，被选为划分属性
- 然后决策树学习算法将对每个分支结点做进一步划分



4.2 划分选择

4.2.1 信息增益

■ 信息增益

■ 例子

- 基于 D^1 计算出各属性的信息增益

$$Gain(D^1, \text{色泽}) = 0.043 \quad Gain(D^1, \text{根蒂}) = 0.458$$

$$Gain(D^1, \text{敲声}) = 0.331 \quad Gain(D^1, \text{脐部}) = 0.458$$

$$Gain(D^1, \text{触感}) = 0.458$$

- 根蒂、脐部、触感3个属性均取得了最大的信息增益，可任选其中之一作为划分属性


4.2 划分选择

4.2.1 信息增益

■ 信息增益

■ 例子

- 对每个分支结点进一步划分，最终得到决策树



4.2 划分选择

4.2.2 增益率

■ 信息增益的缺陷

- 如果属性划分每个分支结点仅包含一个样本，这些分支结点的纯度最大，其信息增益然远大于其他候选属性
- 这样的决策树不具有泛化能力，无法对新样本进行有效预测
- 信息增益对可取值数目较多的属性有偏好

■ 增益率定义(C4.5决策树算法)

$$Gain_ratio(D, a) = \frac{Gain(D, a)}{IV(a)}$$

$$IV(a) = -\sum_{v=1}^V \frac{|D^v|}{D} \log_2 \frac{|D^v|}{D} \quad \text{称为属性} a \text{的固有值}$$

4.2 划分选择

4.2.2 增益率

■ 增益率定义 (C4.5决策树算法)

$$Gain_ratio(D, a) = \frac{Gain(D, a)}{IV(a)}$$

$$IV(a) = - \sum_{v=1}^V \frac{|D^v|}{D} \log_2 \frac{|D^v|}{D}$$

- 属性a的可能取值数目越多，即V越大，则IV(a)的值通常就越大
- 增益率准则对可取值数目较少的属性有所偏好
- C4.5算法不直接选择增益率最大的候选划分属性，而是使用启发式方法
 - 从候选划分属性中找出信息增益高于平均水平的
 - 再从中选取增益率最高的

4.2 划分选择

4.2.3 基尼指数 (CART决策树)

- 数据集D的纯度可用基尼值来度量

$$Gini(D) = \sum_{k=1}^{|y|} \sum_{k' \neq k} p_k p_{k'} = 1 - \sum_{k=1}^{|y|} p_k^2$$


- 反映了从D中随机抽取两个样例，其类别标记不一致的概率
- $Gini(D)$ 越小，数据集D的纯度越高

- 属性a的基尼指数

$$Gini_index(D, a) = \sum_{v=1}^V \frac{|D^v|}{|D|} Gini(D^v)$$

- 在候选属性集合中，选取那个使划分后基尼指数最小的属性，即

$$a_* = \arg \max_{a \in A} Gini_index(D, a)$$



4.3 剪枝处理

■ 过拟合

- 为尽可能正确分类训练样本，结点划分不断重复，会造成决策树分支过多，导致过拟合
- 可通过去掉一些分支来降低过拟合的风险，剪枝是决策树对付“过拟合”的主要手段

■ 剪枝影响

- 研究表明划分选择的各种准则虽然对决策树的尺寸有较大影响，但对泛化性能的影响很有限，如信息增益与基尼指数产生的结果，仅在约2%的情况下不同
- 剪枝方法和程度对决策树泛化性能的影响更为显著，在数据带噪时甚至可能将泛化性能提升25%


4.3 剪枝处理

■ 基本策略

- 预剪枝：提前终止某些分支的生长
 - 对结点在划分前先进行估计
 - 若当前结点的划分不能带来泛化性能提升，则停止划分并将当前结点标记为叶结点
- 后剪枝：生成一棵完全树，再剪枝
 - 先生成完整决策树
 - 然后自底向上对非叶结点进行考察
 - 若将该结点子树替换为叶结点能带来泛化性能提升，则将该子树替换为叶结点

■ 如何判断泛化性能提升

- 可用第2章的性能评估方法



4.3 剪枝处理

例子

- 假定使用留出法，即预留部分数据用作验证集进行能评估
- 采用信息增益准则进行划分属性选择
- 数据集如下(后)

4.3 剪枝处理

例子

数据集


表 4.2 西瓜数据集 2.0 划分出的训练集(双线上部)与验证集(双线下部)

		编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
训练集		1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
		2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
		3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
		6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
		7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
		10	青绿	硬挺	清脆	清晰	平坦	软粘	否
		14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
		15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
		16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
		17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否
验证集		4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
		5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
		8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
		9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
		11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
		12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
		13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

4.3 剪枝处理

例子

■ 未剪枝生成的决策树



4.3 剪枝处理

预剪枝

- 基于信息增益准则，选取属性脐部进行划分

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

结点1：若不划分，则将其标记为叶结点，类别标记为训练样例中最多的类别，若选“好瓜”。验证集中，{4, 5, 8} 被分类正确，得到验证集精度为 $\frac{3}{7} \times 100\% = 42.9\%$

验证集精度

1

脐部=?

“脐部=?” 划分前：42.9%

4.3 剪枝处理


预剪枝

- 基于信息增益准则，选取属性脐部进行划分

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

结点1：若划分，根据结点②，③，④的训练样例，将这3个结点分别标记为“好瓜”、“好瓜”、“坏瓜”。此时，验证集中编号为{4, 5, 8, 11, 12}的样例被划分正确，验证集精度为 $\frac{5}{7} \times 100\% = 71.4\%$



验证集精度

“脐部=?” 划分前：42.9%

划分后：71.4%

预剪枝决策：划分

4.3 剪枝处理

预剪枝


- 基于信息增益准则，对后续结点进行划分

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

对结点②, ③, ④ 分别进行剪枝判断, 结点②, ③都禁止划分, 结点④本身为叶子结点。最终得到仅有一层划分的决策树, 称为“**决策树桩**” (decision stump)

验证集精度



“脐部=?” 划分前: 42.9%
划分后: 71.4%

预剪枝决策: 划分

结点④, 所含训练样例属于同一类, 不再划分

验证集精度

“色泽=?” 划分前: 71.4%

划分后: 57.1%

预剪枝决策: 禁止划分

验证集精度

“根蒂=?” 划分前: 71.4%

划分后: 71.4%


预剪枝决策: 禁止划分

4.3 剪枝处理

■ 预剪枝

■ 优缺点

- 很多分支都没有展开，降低了过拟合的风险，减少了训练时间开销和测试时间开销
- 有些分支的当前划分虽不能提升泛化性能，但在其基础上的后续划分却有可能显著提高性能
- 预剪枝基于贪心本质禁止这些分支展开，给预剪枝决策树带来了欠拟合的风险



4.3 剪枝处理

后剪枝


- 先生成一棵完整的决策树，其验证集精度测得为42.9%



4.3 剪枝处理

后剪枝


- 考虑结点6，若替换为叶结点，根据其上训练样例{7, 5}将其标记为好瓜，测得验证集精度提高至57.1%，于是决定剪枝



4.3 剪枝处理

后剪枝


- 考虑结点6，若替换为叶结点，根据其上训练样例{7, 5}将其标记为好瓜，测得验证集精度提高至57.1%，于是决定剪枝



4.3 剪枝处理

后剪枝

- 考虑结点5，若将其替换为叶结点，根据其训练样例{6, 7, 15}将其标记为好瓜，测得验证集精度仍为57.1%，可以不剪枝



验证集精度

剪枝前: 57.1%


剪枝后: 57.1%

后剪枝决策: 不剪枝

4.3 剪枝处理

后剪枝


- 考虑结点5，若将其替换为叶结点，根据其训练样例{6, 7, 15}将其标记为好瓜，测得验证集精度仍为57.1%，可以不剪枝



4.3 剪枝处理

后剪枝

- 考虑结点2，若将其替换为叶结点，根据其训练样例{1, 2, 3, 14}，将其标记为好瓜，测得验证集精度提升至71.4%，决定剪枝



验证集精度

剪枝前: 57.1%


剪枝后: 71.4%

后剪枝决策: 剪枝

4.3 剪枝处理

后剪枝


- 对结点3和1，先后替换为叶结点，均未测得验证集精度提升，于是不剪枝



4.3 剪枝处理

后剪枝

- 最终后剪枝得到的决策树，其验证集精度为71.4%（原先为42.9%）



4.3 剪枝处理

■ 后剪枝

■ 优缺点

- 保留了更多的分支，欠拟合风险很小，泛化性能往往优于预剪枝决策树
- 在生成完全决策树之后进行，自底向上对所有非叶结点进行考察，训练开销大

■ 预剪枝vs. 后剪枝


■ 时间开销

- 预剪枝：训练时间开销降低，测试时间开销降低
- 后剪枝：训练时间开销增加，测试时间开销降低

■ 过/欠拟合风险

- 预剪枝：过拟合风险降低，欠拟合风险增加
- 后剪枝：过拟合风险降低，欠拟合风险基本不变

■ 泛化性能：后剪枝通常优于预剪枝



4.4 连续与缺失值

4.4.1 连续值处理

■ 问题：

- 生成决策树基于离散属性，使用连续属性，连续属性的可取值数目不再有限
 - 不能直接根据连续属性的可取值来对结点进行划分

■ 基本思路

- 连续属性离散化
 - 如何离散化

4.4 连续与缺失值

4.4.1 连续值处理

■ 二分法 (C4.5)

- 设样本集 D 和连续属性 a , a 在 D 上出现 n 个不同取值, 将值从小到大排序, 记为 $\{a^1, a^2, \dots, a^n\}$
- 基于划分点 t 可将 D 分为子集 D_t^- 和 D_t^+ , 其中 D_t^- 包含不大于 t 的样本, D_t^+ 包含大于 t 的样本
- n 个属性值可形成 $n-1$ 个候选离散划分点集合

$$T_a = \{(a^i + a^{i+1})/2 \mid 1 \leq i \leq n-1\}$$

- 根据划分纯度, 选取最优的划分点
 - 如基于信息增益的最优划分点

$$t = \arg \max_{t \in T_a} \text{Gain}(D, a, t)$$

$$= \arg \max_{t \in T_a} \left[\text{Ent}(D) - \sum_{\lambda \in \{-, +\}} \frac{|D_t^\lambda|}{|D|} \text{Ent}(D_t^\lambda) \right]$$

4.4 连续与缺失值

4.4.1 连续值处理

■ 二分法

■ 例：基于信息增益的最优划分点

表 4.3 西瓜数据集 3.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否


4.4 连续与缺失值


4.4.1 连续值处理

■ 二分法

■ 例：基于信息增益的最优划分点

- 对属性密度，候选划分点集合包含16个候选值根据前面的式子可得 $t_{\text{密度}}=0.381$
- 对属性含糖率，候选划分点集合也包含16个候选值根据前面的式子可得 $t_{\text{含糖率}}=0.126$
- 然后根据各属性的信息增益最终生成决策树
 - 与离散属性不同，连续属性还可作为其后代结点的划分属性





4.4 连续与缺失值

4.4.2 缺失值处理

- 属性值缺失现象

- 不完整样本，即样本的某些属性值缺失
- 由于属性较多、隐私保护等因素
- 仅使用无缺失值的样例，对数据信息是极大浪费

- 使用带缺失值的样例

- 如何在属性值缺失的情况下进行划分属性选择
- 给定划分属性，样本在该属性值缺失，如何划分

4.4 连续与缺失值

4.4.2 缺失值处理

■ 基本思路：样本赋权，权重划分

- 给定训练集 D 和属性 a ， $\tilde{D}$ 表示 D 中属性 a 上没有缺失值的样本子集(问题1)
- 对于划分属性选择，根据 $\tilde{D}$ 判断属性 a 的优劣
 - 设 a 有 V 个取值， $\tilde{D}^v$ 表示 $\tilde{D}$ 中属性取值 a^v 的样本子集
 - $\tilde{D}_k$ 表示 D 中属于第 k 类 ($k=1,2,\dots,|y|$)的样本子集
 - 为每个样本 x 赋予一个权重 w_x ，定义

$$\rho = \sum_{x \in \tilde{D}} w_x / \sum_{x \in D} w_x$$

- 无缺失值样本所占比例

$$\tilde{p}_k = \sum_{x \in \tilde{D}_k} w_x / \sum_{x \in \tilde{D}} w_x, \quad (1 \leq k \leq |y|)$$

- 无缺失值样本中第 k 类所占比例

$$\tilde{r}_v = \sum_{x \in \tilde{D}^v} w_x / \sum_{x \in \tilde{D}} w_x, \quad (1 \leq v \leq V)$$

- 无缺失值样本属性 a 取值 a^v 样本所占比例

4.4 连续与缺失值

4.4.2 缺失值处理

- 基本思路：样本赋权，权重划分

- 对于划分属性选择，根据 $\tilde{D}$ 判断属性 a 的优劣
 - 信息增益计算式变为

$$\begin{aligned} Gain(D, a) &= \rho \times Gain(\tilde{D}, a) \\ &= \rho \times \left[Ent(\tilde{D}) - \sum_{v=1}^V \tilde{r}_v Ent(\tilde{D}^v) \right] \end{aligned}$$

- 其中

$$Ent(\tilde{D}) = - \sum_{k=1}^{|y|} \tilde{p}_k \log_2 \tilde{p}_k$$

- 对于属性值缺失(问题2)

- 若样本 x 的 a 属性取值已知，将 x 划入对应的子结点，且样本权值在子结点中保持为 w_x
- 若样本 x 的 a 属性取值未知，将 x 同时划入所有子结点，且样本权值调整为 $\tilde{r}_v w_x$

4.4 连续与缺失值

4.4.2 缺失值处理

- 基本思路：样本赋权，权重划分

- 例子

- 学习开始，根结点包含样例集D全部样例，权重均为1

表 4.4 西瓜数据集 2.0 α

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	—	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	—	是
3	乌黑	蜷缩	—	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	—	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	—	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	—	稍凹	硬滑	是
9	乌黑	—	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	—	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	—	否
12	浅白	蜷缩	—	模糊	平坦	软粘	否
13	—	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	—	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	—	沉闷	稍糊	稍凹	硬滑	否

4.4 连续与缺失值

4.4.2 缺失值处理

■ 基本思路：样本赋权，权重划分

■ 例子

■ 属性色泽的信息增益

- 对于属性色泽，无缺失值样例子集 $\tilde{D}$ 包含14个样例，信息熵为

$$Ent(\tilde{D}) = -\sum_{k=1}^2 \tilde{p}_k \log_2 \tilde{p}_k = -(\frac{6}{14} \log_2 \frac{6}{14} + \frac{8}{14} \log_2 \frac{8}{14}) = 0.985$$

令 $\tilde{D}^1, \tilde{D}^2, \tilde{D}^3$ 分别表示在属性色泽取值为青绿、乌黑、浅白的样本子集，则有

$$Ent(\tilde{D}^1) = -(\frac{2}{4} \log_2 \frac{2}{4} + \frac{2}{4} \log_2 \frac{2}{4}) = 1, \quad Ent(\tilde{D}^2) = -(\frac{4}{6} \log_2 \frac{4}{6} + \frac{2}{6} \log_2 \frac{2}{6}) = 0.918$$

$$Ent(\tilde{D}^3) = -(\frac{0}{4} \log_2 \frac{0}{4} + \frac{4}{4} \log_2 \frac{4}{4}) = 0$$

样本子集 $\tilde{D}$ 上属性色泽的信息增益为

$$\begin{aligned} \text{Gain}(\tilde{D}, \text{色泽}) &= Ent(\tilde{D}) - \sum_{v=1}^3 \tilde{r}_v Ent(\tilde{D}^v) \\ &= 0.985 - \left(\frac{4}{14} \times 1.000 + \frac{6}{14} \times 0.918 + \frac{4}{14} \times 0.000 \right) \\ &= 0.306 \end{aligned}$$

无缺失值样例中属性 a 取值为 v 的占比

4.4 连续与缺失值

4.4.2 缺失值处理

- 基本思路：样本赋权，权重划分

- 例子

- 属性色泽的信息增益

- 对于属性色泽，样本集D的属性色泽信息增益为

$$\text{Gain}(D, \text{色泽}) = \underbrace{\rho}_{\text{无缺失值样例占比}} \times \text{Gain}(\tilde{D}, \text{色泽}) = \frac{14}{17} \times 0.306 = 0.252$$

- 类似地可计算出所有属性在数据集上的信息增益

$$\text{Gain}(D, \text{色泽}) = 0.252 \quad \text{Gain}(D, \text{根蒂}) = 0.171$$

$$\text{Gain}(D, \text{敲声}) = 0.145 \quad \text{Gain}(D, \text{纹理}) = 0.424$$

$$\text{Gain}(D, \text{脐部}) = 0.289 \quad \text{Gain}(D, \text{触感}) = 0.006$$

4.4 连续与缺失值

4.4.2 缺失值处理

■ 基本思路：样本赋权，权重划分

■ 例子

■ 通过属性纹理的划分

进入“纹理=清晰”分支

进入“纹理=稍糊”分支

进入“纹理=模糊”分支

样本权重在各子结点仍为1

在“纹理”上出现缺失值，
样本 8, 10 同时进入三个
分支，三支上的权重分
别为 $7/15$, $5/15$, $3/15$

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	-	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	-	是
3	乌黑	蜷缩	-	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	-	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	-	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	-	稍凹	硬滑	是
9	乌黑	-	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	-	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	-	否
12	浅白	蜷缩	-	模糊	平坦	软粘	否
13	-	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	-	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	-	沉闷	稍糊	稍凹	硬滑	否

权重划分


4.4 连续与缺失值

4.4.2 缺失值处理

■ 基本思路：样本赋权，权重划分

■ 例子

■ 结点划分过程递归执行，最终生成的决策树



4.5 多变量决策树



■ 轴平行划分

- 单变量决策树在每个非叶结点仅考虑一个划分属性
- 若把每个属性视为坐标空间中的一个坐标轴，则 d 个属性描述的样本就对应了 d 维空间中的一个数据点
- 对样本分类意味着在这个坐标空间中寻找不同类样本之间的分类边界
 - 形成的分类边界有一个明显的特点，轴平行，即它的分类边界由若干个与坐标轴平行的分段组成

4.5 多变量决策树

轴平行划分

例




编号	密度	含糖率	好瓜
1	0.697	0.460	是
2	0.774	0.376	是
3	0.634	0.264	是
4	0.608	0.318	是
5	0.556	0.215	是
6	0.403	0.237	是
7	0.481	0.149	是
8	0.437	0.211	是
9	0.666	0.091	否
10	0.243	0.267	否
11	0.245	0.057	否
12	0.343	0.099	否
13	0.639	0.161	否
14	0.657	0.198	否
15	0.360	0.370	否
16	0.593	0.042	否
17	0.719	0.103	否

4.5 多变量决策树

■ 轴平行vs. 倾斜

- 轴平行分类边界有较好的可解释性
- 当学习任务所对应的分类边界很复杂时，需要非常多段划分才能获得较好的近似
 - 决策树复杂，要大量的属性测试，预测时间也大
- 若使用斜的划分边界，决策树将大为简化
 - 多变量决策树



4.5 多变量决策树

■ 多变量决策树

- 能实现斜划分甚至更复杂划分
- 如斜划分的多变量决策树
 - 非叶结点不是对某个属性，而是对属性的线性组合进行测试，即每个非叶结点是一个线性分类器




$$\sum_{i=1}^d w_i a_i = t$$

- w_i 和 t 在该结点所含的样本集和属性集上学得
- 每个非叶结点不是寻找最优划分属性，而是试图建立一个合适的线性分类器

4.5 多变量决策树


多变量决策树

- 如斜划分的多变量决策树



编号	密度	含糖率	好瓜
1	0.697	0.460	是
2	0.774	0.376	是
3	0.634	0.264	是
4	0.608	0.318	是
5	0.556	0.215	是
6	0.403	0.237	是
7	0.481	0.149	是
8	0.437	0.211	是
9	0.666	0.091	否
10	0.243	0.267	否
11	0.245	0.057	否
12	0.343	0.099	否
13	0.639	0.161	否
14	0.657	0.198	否
15	0.360	0.370	否
16	0.593	0.042	否
17	0.719	0.103	否

更复杂的“混合决策树”甚至可以在结点嵌入神经网络或其他非线性模型



作业

4. 3、 4. 4、 4. 5、 4. 6