

第6章 支持向量机



主要内容

- 间隔与支持向量
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归
- 核方法

6.0 SVM与统计学习简史


- 1963年, Vapnik提出支持向量的概念
- 1968年, Vapnik和Chervonenkis提出VC维
- 1974年, 提出结构风险最小化原则
- 1995年, Support Vector Network文章发表
- 1995年, 《The Nature of Statistical Learning》出版
- 1998年, SVM在文本分类上取得巨大成功
- 1998年, 《Statistical Learning Theory》出版



6.1 间隔与支持向量

■ 线性分类器回顾


- 给定训练集 $D=\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_m, y_m)\}, y_i \in \{-1, +1\}$, 分类学习最基本思想就是基于训练集D在样本空间中找到一个划分超平面, 将不同类别的样本分开



6.1 间隔与支持向量

■ 线性分类器回顾

- 但将训练样本分开的划分超平面可能有很多，哪一个更好
 - 正中间红色的划分超平面
 - 对训练样本局部扰动、噪声的容忍性最好，受影响最小，鲁棒性最好，对未见示例的泛化能力最强



6.1 间隔与支持向量


■ 超平面方程

- 样本空间划分超平面的线性方程

$$\mathbf{w}^T \mathbf{x} + b = 0$$

- $\mathbf{w} = (w_1; w_2; \dots; w_d)$ 为法向量，决定超平面的方向
- b 为位移项，决定了平面与原点之间的距离

- 样本点到超平面的距离 $r = \frac{|\mathbf{w}^T \mathbf{x} + b|}{\|\mathbf{w}\|}$



6.1 间隔与支持向量


支持向量

- 假设超平面 $(\hat{w}, \hat{b})$ 将训练样本正确分类，则对于 $(x_i, y_i) \in D$ ，有

$$\begin{cases} \hat{w}^T x_i + \hat{b} > 0, & y_i = +1 \\ \hat{w}^T x_i + \hat{b} < 0, & y_i = -1 \end{cases} \quad r = \frac{|w^T x + b|}{\|w\|}$$

- 将上式缩放变换有

$$\begin{cases} w^T x_i + b \geq +1, & y_i = +1 \\ w^T x_i + b \leq -1, & y_i = -1 \end{cases}$$



- 距离超平面最近的训练样本点能使等号成立，这些点被称为支持向量
- 两个异类支持向量到超平面的距离之和为 $\gamma = \frac{2}{\|w\|}$ ，称为间隔

6.1 间隔与支持向量

■ 支持向量机基本型

- 确定最好分类器就是要找到具有最大间隔的划分超平面，也就是找使 γ 最大的参数 (w, b) 即

$$\begin{aligned} & \operatorname{argmax}_{w, b} \frac{2}{\|w\|} \\ & s.t. \quad y_i \times (w^T x_i + b) \geq 1, \quad i=1 \dots m. \end{aligned}$$

- 其等价于

$$\begin{aligned} & \operatorname{argmin}_{w, b} \frac{\|w\|^2}{2} \\ & s.t. \quad y_i \times (w^T x_i + b) \geq 1, \quad i=1 \dots m. \end{aligned}$$

- 这是支持向量机(SVM)的基本型
- 是凸二次规划问题，如何求解

6.2 对偶问题

■ 用拉格朗日乘子法求解

- 对支持向量机基本型的约束引入拉格朗日乘子 $\alpha=(\alpha_1,\dots,\alpha_m), \alpha_i \geq 0$, 则问题拉格朗日函数为

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^m \alpha_i [1 - y_i (\mathbf{w}^T \mathbf{x}_i + b)]$$

- 令 $\mathbf{w}, b$ 的偏导为零有

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \quad 0 = \sum_{i=1}^m \alpha_i y_i$$

- 上式代入原式消去 $\mathbf{w}, b$ 得对偶问题

$$\arg \max_{\boldsymbol{\alpha}} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

$$s.t. \quad \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i=1, 2, \dots, m$$

6.2 对偶问题

■ 解的稀疏性

- 解出 α 求得 w, b 可得模型

$$f(\mathbf{x}) = \mathbf{w}\mathbf{x} + b = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^T \mathbf{x} + b$$

- α_i 对应训练样本 $(\mathbf{x}_i, y_i)$
- 求解过程需满足KKT条件

$$\begin{cases} \alpha_i \geq 0 \\ y_i f(\mathbf{x}_i) - 1 \geq 0 \\ \alpha_i [y_i f(\mathbf{x}_i) - 1] = 0 \end{cases} \Rightarrow \begin{matrix} \alpha_i = 0 \\ \text{or} \\ y_i f(\mathbf{x}_i) = 1 \end{matrix} \quad \begin{matrix} \text{样本不出现} \\ \\ \mathbf{x}_i \text{是支持向量} \end{matrix}$$

- 训练完成后最终模型仅与支持向量有关，这是解的稀疏性

6.2 对偶问题


■ α 求解

- 求解式是二次规划问题，可用二次规划算法来求解
 - 但问题规模正比于训练样本数，造成很大开销
- 利用问题本身特性的一些高效算法
 - 如SMO(Sequential Minimal Optimization序列最小优化算法)
 - 基本思路：先固定 α_i 之外的所有参数，然后求 α_i 上的极值
 - 基本步骤
 - 每次选择两个变量 α_i, α_j
 - 固定其他参数，求解获得更新后的 α_i, α_j
 - 不断执行如上两个步骤直至收敛

6.3 核函数

■ 特征空间映射

- 若不存在能正确划分两类样本的超平面
 - 可将样本从原始空间映射到一个更高维的特征空间，使样本在这个特征空间内线性可分
 - 如异或问题，若将原二维空间映射到合适的三维空间，就能找到划分超平面
 - 如果原始空间是有限维(属性数有限)，那么一定存在一个高维特征空间使样本可分



6.3 核函数

■ 特征空间映射

- 设 $\phi(x)$ 表示将 x 映射后的特征向量，特征空间的划分超平面为

$$f(x) = \mathbf{w}^T \phi(x) + b$$

- 特征空间的学习问题为

$$\operatorname{argmin}_{\mathbf{w}, b} \frac{\|\mathbf{w}\|^2}{2}$$

$$s.t. \quad y_i [\mathbf{w}^T \phi(\mathbf{x}_i) + b] \geq 1, \quad i=1, 2, \dots, m$$

- 其对偶问题

$$\operatorname{argmin}_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \underbrace{\phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)}$$

$$s.t. \quad \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i=1, 2, \dots, m$$

只以内积形式出现，但特征空间维数可能很高

- 从而预测出 $f(x) = \mathbf{w}^T \phi(x) + b = \sum_{i=1}^m \alpha_i y_i \underbrace{\phi(\mathbf{x}_i)^T \phi(x)} + b$

6.3 核函数

■ 基本思路

- 特征空间维数可能很高，直接计算 $\phi(x_i)^T \phi(x_j)$ 通常困难
- 设计函数

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) \quad \text{核函数}$$

- 绕过显式考虑特征映射以及计算高维内积的困难
- 对偶问题

$$\operatorname{argmin}_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \kappa(\mathbf{x}_i, \mathbf{x}_j)$$

$$s.t. \quad \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i=1, 2, \dots, m$$

最优解可
通过训练
样本的核
函数展开

- 求解后模型可写为

$$f(x) = \sum_{i=1}^m \alpha_i y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b$$

支持向量展式

6.3 核函数

■ 基本思路

■ 设计核函数

- 若已知映射 $\phi(\cdot)$ 的具体形式, 则可得核函数 $\kappa(\cdot, \cdot)$
 - 在现实任务中通常 $\phi(\cdot)$ 未知
 - 什么样的函数能做核函数
- Mercer定理
 - 若一个对称函数所对应的核矩阵(如下)半正定, 则它就能作为核函数来使用

$$\mathbf{K} = \begin{bmatrix} \kappa(\mathbf{x}_1, \mathbf{x}_1) & \cdots & \kappa(\mathbf{x}_1, \mathbf{x}_j) & \cdots & \kappa(\mathbf{x}_1, \mathbf{x}_m) \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ \kappa(\mathbf{x}_i, \mathbf{x}_1) & \cdots & \kappa(\mathbf{x}_i, \mathbf{x}_j) & \cdots & \kappa(\mathbf{x}_i, \mathbf{x}_m) \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ \kappa(\mathbf{x}_m, \mathbf{x}_1) & \cdots & \kappa(\mathbf{x}_m, \mathbf{x}_j) & \cdots & \kappa(\mathbf{x}_m, \mathbf{x}_m) \end{bmatrix}$$

6.3 核函数

核函数的选择

■ 重要性

- 要样本在特征空间内线性可分，特征空间的好坏对支持向量机的性能至关重要
- 若选择不合适，样本将映射到不合适的特征空间，可能导致性能不佳

■ 常用核函数

名称	表达式	参数
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$	
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T \mathbf{x}_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\sigma^2}\right)$	$\sigma > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\sigma}\right)$	$\sigma > 0$
Sigmoid 核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^T \mathbf{x}_j + \theta)$	$\tanh$ 为双曲正切函数, $\beta > 0, \theta < 0$

- 文本数据常用线性核，情况不明可先尝试高斯核

6.3 核函数

■ 核函数的选择

■ 可通过函数组合得到

- 若 κ_1, κ_2 是核函数, 则对任意正数 γ_1, γ_2 和任意函数 $g(\mathbf{x})$

$$\left. \begin{array}{l} \gamma_1 \kappa_1 + \gamma_2 \kappa_2 \\ \kappa_1 \otimes \kappa_2(\mathbf{x}, \mathbf{z}) \\ g(\mathbf{x}) \kappa_1(\mathbf{x}, \mathbf{z}) g(\mathbf{x}) \end{array} \right\} \text{核函数}$$


6.4 软间隔与正则化

问题

- 现实中很难确定合适的核函数，使训练样本在特征空间中线性可分
- 即便貌似线性可分，也很难断定是否是因过拟合造成的

■ 引入软间隔概念

- 软间隔概念，允许SVM在一些样本上出错、不满足约束
- 完全满足称为硬间隔



6.4 软间隔与正则化

■ 优化目标

- 基本思路：最大化间隔的同时，让不满足约束 $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$ 的样本尽可能少

- 优化目标可写为

$$\operatorname{argmin}_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m l_{0/1} [y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- $C > 0$ 是常数

- 无穷大时，迫使所有样本均满足约束
- 取有限值时，允许一些样本不满足约束

- $l_{0/1}$ 是0/1损失函数 $l_{0/1}(z) = \begin{cases} 1, & z < 0 \\ 0, & \text{otherwise} \end{cases}$

- 函数非凸、非连续，不易优化直接求解
- 因此常用其他一些函数来代替，称为替代损失

6.4 软间隔与正则化

替代损失

- 一般具有较好的数学性质
 - 如它们通常是凸的连续函数
 - 且是0/1损失函数的上界


- 三种常用的替代损失函数

- hinge损失: $l_{\text{hinge}}(z) = \max(0, 1 - z)$

- 指数损失: $l_{\text{exp}}(z) = \exp(-z)$

- 对数损失: $l_{\log}(z) = \log[1 + \exp(-z)]$

- 采用替代损失函数，是解决困难问题的常见技巧
- 求解替代函数得到的解是否仍是原问题的解？称为替代损失的一致性问题



6.4 软间隔与正则化

■ 软间隔支持向量机

- 若采用hinge损失，则问题变成

$$\operatorname{argmin}_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \max[0, 1 - y_i(w^T x_i + b)]$$

- 引入松弛变量 ξ_i (每个松弛变量对应一个样本，表征该样本不满足约束的程度)，上式可写为

$$\operatorname{argmin}_{w,b,\xi_i} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i$$

$$s.t. \quad y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i=1, \dots, m$$

- 二次规划问题，通过拉格朗日乘子法可得对偶问题

$$\operatorname{argmin}_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$s.t. \quad \sum_{i=1}^m \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i=1, 2, \dots, m$$

与硬间隔
SVM的区别

- 根据KKT条件，最终模型仅与支持向量有关，也即采用hinge 损失函数后仍保持了SVM解的稀疏性

6.4 软间隔与正则化

■ 正则化

- 如果使用对率损失函数 $l_{\log}$ 来替代损失函数，几乎就是对率回归模型
 - 支持向量机与对率回归优化目标相近，性能相当
 - 对率回归的优势是输出具有概率意义，支持向量机没有
 - 对率回归能直接用于多分类任务，支持向量机需推广
- 统计学习模型的更一般形式
 - 把0/1损失函数换成别的替代损失函数以得到其他学习模型，其性质与所用的替代函数直接相关
 - 但它们具有共性
 - 优化目标的第一项用来描述划分超平面的间隔大小
 - 另一项 $\sum_{i=1}^m l(f(x_i), y_i)$ 表述训练集上的误差

6.4 软间隔与正则化

■ 正则化

■ 统计学习模型的更一般形式

■ 模型可写为更一般的形式

$$\operatorname{argmin}_f \underbrace{\Omega(f)}_{\text{结构风险}} + C \sum_{i=1}^m \underbrace{l(f(x_i), y_i)}_{\text{经验风险}}$$

- 结构风险：描述模型 f 的某些性质
 - 从经验风险最小化来看，表述了希望获得具有何种性质的模型，可引入领域知识
 - 有助于削减假设空间，从而降低了最小化训练误差的过拟合风险
 - 从正则化问题角度，称为正则化项，范数 L_p 是常用的正则化项
 - 从贝叶斯估计角度，可认为是模型的先验概率
- 经验风险：描述模型与训练数据的契合程度
- C 用于对二者进行折中，也称为正则化常数

6.5 支持向量回归

■ 回归问题

- 给定训练样本 $D=\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_m, y_m)\}, y_i \in R$, 学得回归模型 $f(\mathbf{x}) = \mathbf{w}\mathbf{x} + b$, 使 $f(\mathbf{x})$ 和 y 尽可能接近
 - 传统回归模型直接基于模型输出与真实输出之间的差别来计算损失


■ 基本思路

- 允许模型输出与实际输出间存在 ε 的差别
 - 当 $f(x)$ 与 y 的差别绝对值大于 ε 时才计算损失
 - 差别绝对值小于 ε 认为是被预测正确的

6.5 支持向量回归

基本思路

- 允许模型输出与实际输出间存在 ϵ 的差别



6.5 支持向量回归


基本思路

- SVR问题可表示为

$$\operatorname{argmin}_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m l_{\varepsilon}(f(x_i) - y_i)$$

- C为正则化常数

- l_{ε} 为 ε -不敏感损失函数 $l_{\varepsilon}(z) = \begin{cases} 0, & |z| \leq \varepsilon \\ |z| - \varepsilon, & \text{otherwise} \end{cases}$



6.5 支持向量回归

求解

- 引入松弛变量 $\xi_i, \hat{\xi}_i$, 原始问题为

$$\operatorname{argmin}_{\mathbf{w}, b, \xi_i, \hat{\xi}_i} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m (\xi_i + \hat{\xi}_i)$$

$$\text{s.t. } f(\mathbf{x}_i) - y_i \leq \varepsilon + \xi_i,$$

$$y_i - f(\mathbf{x}_i) \leq \varepsilon + \hat{\xi}_i,$$

$$\xi_i \geq 0, \hat{\xi}_i \geq 0, i=1, \dots, m$$

- 利用拉格朗日乘子法可得对偶问题

$$\max_{\alpha, \hat{\alpha}} \sum_{i=1}^m [y_i(\hat{\alpha}_i - \alpha_i) - \varepsilon(\hat{\alpha}_i + \alpha_i)] - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m (\hat{\alpha}_i - \alpha_i)(\hat{\alpha}_j - \alpha_j) \mathbf{x}_i^T \mathbf{x}_j$$

$$\text{s.t. } \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) = 0, 0 \leq \alpha_i, \hat{\alpha}_i \leq C$$

6.5 支持向量回归

■ 求解

- 根据KKT条件可得解

$$f(\mathbf{x}) = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) \mathbf{x}_i^T \mathbf{x} + b$$

- 支持向量必落在间隔带之外
- 支持向量仅是训练样本的一部分，其解具有稀疏性

- 若考虑特征映射 $\mathbf{w} = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) \phi(\mathbf{x}_i)$ ，SVR解为

$$f(\mathbf{x}) = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) \kappa(\mathbf{x}, \mathbf{x}_i) + b$$

- $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$ 为核函数

6.6 核方法

■ 表示定理

- 无论SVM还是SVR，学得模型总能表示为核函数的线性组合

- 核SVM: $f(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + b = \sum_{i=1}^m \alpha_i y_i \kappa(\mathbf{x}, \mathbf{x}_i) + b$

- 核SVR: $f(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + b = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) \kappa(\mathbf{x}, \mathbf{x}_i) + b$

- 更一般的结论(表示定理)

- 对于任意单调递增函数 $\Omega: [0, \infty] \mapsto R$ 和任意非负损失函数 $l: R^m \mapsto [0, \infty]$ ，优化问题

$$\min_{h \in H} F(h) = \Omega(\|h\|_H) + l(h(\mathbf{x}_1), \dots, h(\mathbf{x}_m))$$

的解总可以写为 $h^*(\mathbf{x}) = \sum_{i=1}^m \alpha_i \kappa(\mathbf{x}, \mathbf{x}_i)$

- 核函数的线性组合
- 这显示出核函数的巨大作用

6.6 核方法

核方法

- 基于核函数的学习方法统称为核方法。引入核函数称为核化
- 通常用核化将线性学习器拓展为非线性学习器
- 例：核线性判别分析KLDA
 - 通过某种映射 $\phi: X \mapsto F$ 将样本映射到高维特征空间 F ，然后在此特征空间中做线性判别分析 $h(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x})$
 - 学习目标
$$\arg \max_{\mathbf{w}} \frac{\mathbf{w}^T \mathbf{S}_b^\phi \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w^\phi \mathbf{w}}$$
 - F 中的类间散度矩阵 $\mathbf{S}_b^\phi = (\boldsymbol{\mu}_1^\phi - \boldsymbol{\mu}_0^\phi)(\boldsymbol{\mu}_1^\phi - \boldsymbol{\mu}_0^\phi)^T$
 - 类内散度矩阵 $\mathbf{S}_w^\phi = \sum_{i=0}^1 \sum_{\mathbf{x} \in X_i} [\phi(\mathbf{x}) - \boldsymbol{\mu}_i^\phi][\phi(\mathbf{x}) - \boldsymbol{\mu}_i^\phi]^T$
 - 第 i 类样本在特征空间 F 中的均值
$$\boldsymbol{\mu}_i^\phi = \frac{1}{m_i} \sum_{\mathbf{x} \in X_i} \phi(\mathbf{x})$$
 X_i 为第 i 类样本集合， m_i 为样本数

6.6 核方法

核方法

■ 例：核线性判别分析KLDA

- 通常难以知道映射 ϕ 的具体形式，通过引入核函数 $h(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) = \sum_{i=1}^m \alpha_i \kappa(\mathbf{x}, \mathbf{x}_i)$ ，有

$$\arg \max_{\alpha} J(\alpha) = \frac{\alpha^T M \alpha}{\alpha^T N \alpha}$$

$$M = (\hat{\mu}_0 - \hat{\mu}_1)(\hat{\mu}_0 - \hat{\mu}_1)^T$$


$$N = \mathbf{K} \mathbf{K}^T - \sum_{i=0}^1 m_i \hat{\mu}_i \hat{\mu}_i^T$$

$$\hat{\mu}_0 = \frac{1}{m_0} \mathbf{K} \mathbf{1}_0$$

$$\hat{\mu}_1 = \frac{1}{m_1} \mathbf{K} \mathbf{1}_1$$

$\mathbf{K}$ 为核矩阵

- 使用线性判别分析求解方法即可得到 α



作业

6.2、6.8