


第9章 聚类



主要内容

- 聚类任务
- 性能度量
- 距离计算
- 原型聚类
- 密度聚类
- 层次聚类



9.1 聚类任务

■ 无监督学习

- 训练样本的标记信息未知，通过对无标记训练样本的学习来揭示数据的内在性质及规律
- 聚类、密度估计、异常检测

■ 聚类

- 将数据集中的样本划分为若干个不相交的子集，每个子集称为一个簇
 - 通过划分，每个簇可能对应一些潜在的概念类别
 - 这些概念对聚类算法而言事先是未知的
 - 聚类过程仅能自动形成簇结构，其对应的概念语义要使用者来把握和命名
- 可以作为一个单独过程(用于找寻数据内在的分布结构)，也可作为分类等其他学习任务的前驱过程

9.1 聚类任务

聚类

- 聚类算法涉及的两个基本问题

- 性能度量
- 距离计算

- 符号表示

- 样本集 $D=\{\mathbf{x}_1, \dots, \mathbf{x}_m\}$ 包含 m 个无标记样本
- 每个样本 $\mathbf{x}_i=\{\mathbf{x}_{i1}, \dots, \mathbf{x}_{in}\}$ 是一个 n 维特征向量
- 聚类是将样本集 D 划分为 k 个不相交簇 $\{C_l | l=1, \dots, k\}$
且 $C_{l'} \cap_{l' \neq l} C_l = \emptyset, \bigcup_{l=1}^k C_l$
- $\lambda_j \in \{1, \dots, k\}$ 表示样本 $\mathbf{x}_j$ 的簇标记, $\mathbf{x}_j \in C_{\lambda_j}$, 簇标记向量 $\lambda=(\lambda_1, \dots, \lambda_k)$



9.2 性能度量

- 亦称聚类有效性指标

- 作用

- 对聚类结果，通过性能度量评估其好坏
- 可将其作为聚类过程的优化目标，从而得到符合要求的聚类结果

- 评估基本想法

- 簇内相似度高
- 且簇间相似度低

- 两类方法

- 外部指标
 - 将聚类结果与某参考模型进行比较
- 内部指标
 - 直接考察聚类结果而不用任何参考模型

9.2 性能度量

■ 外部指标

■ 符号表示

- 通过聚类给出的簇划分为 $C=\{C_1,...,C_k\}$
- 参考模型给出的簇划分为 $C^*=\{C_1^*,...,C_k^*\}$
- λ, λ^* 分别表示与 C, C^* 对应的簇标记向量
- 定义 $a=|SS|$, $SS=\{(\mathbf{x}_i, \mathbf{x}_j) | \lambda_i = \lambda_j, \lambda_i^* = \lambda_j^*, i < j\}$
 $b=|SD|$, $SD=\{(\mathbf{x}_i, \mathbf{x}_j) | \lambda_i = \lambda_j, \lambda_i^* \neq \lambda_j^*, i < j\}$
 $c=|DS|$, $DS=\{(\mathbf{x}_i, \mathbf{x}_j) | \lambda_i \neq \lambda_j, \lambda_i^* = \lambda_j^*, i < j\}$
 $d=|DD|$, $DD=\{(\mathbf{x}_i, \mathbf{x}_j) | \lambda_i \neq \lambda_j, \lambda_i^* \neq \lambda_j^*, i < j\}$

■ $a+b+c+d=m(m-1)/2$

■ Jaccard系数(JC)

$$JC = a / (a + b + c)$$

■ FM指数(FMI)

$$FMI = \sqrt{\frac{a}{a+b} \cdot \frac{a}{a+c}}$$

9.2 性能度量

■ 外部指标

- Rand指数 (RI) $RI = [2(a+d)]/[m(m-1)]$
- 上述性能度量值均在 $[0, 1]$ ，值越大越好

■ 内部指标

■ 符号和定义

- 两样本间距离 $dist(\mathbf{x}_i, \mathbf{x}_j)$
- 簇C的中心点 $\mu = \frac{1}{|C|} \sum_{1 \leq i \leq |C|} \mathbf{x}_i$
- 簇内样本间平均距离 $avg(C) = \frac{2}{|C|(|C|-1)} \sum_{1 \leq i < j \leq |C|} dist(\mathbf{x}_i, \mathbf{x}_j)$
- 簇内样本间最远距离 $diam(C) = \max_{1 \leq i < j \leq |C|} dist(\mathbf{x}_i, \mathbf{x}_j)$
- 两簇最近样本间距离 $d_{\min}(C_i, C_j) = \min_{\mathbf{x}_i \in C_i, \mathbf{x}_j \in C_j} dist(\mathbf{x}_i, \mathbf{x}_j)$
- 两簇中心点间的距离 $d_{cen}(C_i, C_j) = dist(\mu_i, \mu_j)$

9.2 性能度量

■ 内部指标

■ DB指数 (DBI)

$$DBI = \frac{1}{k} \sum_{i=1}^k \max \left(\frac{avg(C_i) + avg(C_j)}{d_{cen}(C_i, C_j)} \right)$$

- 值越小越好

■ Dunn指数 (DI)

$$DI = \min_{1 \leq i \leq k} \left[\min_{j \neq i} \left(\frac{d_{\min}(C_i, C_j)}{\max_{1 \leq l \leq k} diam(C_l)} \right) \right]$$

- 值越大越好

9.3 距离计算

■ 距离度量

■ 需满足四个基本性质

- 非负性 $dist(\mathbf{x}_i, \mathbf{x}_j) \geq 0$
- 同一性 $dist(\mathbf{x}_i, \mathbf{x}_j) = 0$ 当且仅当 $\mathbf{x}_i = \mathbf{x}_j$
- 对称性 $dist(\mathbf{x}_i, \mathbf{x}_j) = dist(\mathbf{x}_j, \mathbf{x}_i)$
- 直递性 $dist(\mathbf{x}_i, \mathbf{x}_j) \leq dist(\mathbf{x}_i, \mathbf{x}_k) + dist(\mathbf{x}_k, \mathbf{x}_j)$

■ 闵可夫斯基距离

$$dist_{mk}(\mathbf{x}_i, \mathbf{x}_j) = \left(\sum_{u=1}^n |x_{iu} - x_{ju}|^p \right)^{\frac{1}{p}}, \quad p \geq 1$$

- $p=1$ 时，曼哈顿距离

$$dist_{man}(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_1 = \sum_{u=1}^n |x_{iu} - x_{ju}|$$

- $p=2$ 时，欧氏距离

$$dist_{ed}(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\| = \sqrt{\sum_{u=1}^n |x_{iu} - x_{ju}|^2}$$

9.3 距离计算

■ 距离度量

■ 离散属性

■ 有序属性

- 离散属性值之间有序关系
- 能直接在属性值上计算距离，使用闵可夫斯基距离

■ 无序属性

- 离散属性值之间没有序关系，如{飞机, 火车, 轮船}
- 可采用VDM(Value Difference Metric)
 - 属性 u 上取值为 a 的样本数 $m_{u,a}$ ，样本簇数 k
 - 第 i 个样本簇中属性 u 上取值为 a 的样本数 $m_{u,a,i}$
 - 属性 u 上两个离散值 a, b 间的VDM距离为

$$VDM_p(a, b) = \sum_{i=1}^k \left| \frac{m_{u,a,i}}{m_{u,a}} - \frac{m_{u,b,i}}{m_{u,b}} \right|^p$$

9.3 距离计算

距离度量

■ 混合属性

- 将闵可夫斯基距离和VDM结合
- 有 n_c 个有序属性、 $n-n_c$ 个无序属性，有序属性排列在无序属性之前，则

$$MinkovDM_p(\mathbf{x}_i, \mathbf{x}_j) = \left[\sum_{u=1}^{n_c} |x_{iu} - x_{ju}|^p + \sum_{u=n_c+1}^n VDM_p(x_{iu}, x_{ju}) \right]^{\frac{1}{p}}$$


- 当属性重要性不同时，可用加权距离

$$w_i \geq 0 (i=1, \dots, n), \quad \sum_{i=1}^n w_i = 1$$

■ 非度量距离

- 实际中用于相似度量度的距离未必满足距离度量所有基本性质，如直递性

- 要基于数据样本来确定合适的距离计算式



9.4 原型聚类

■ 亦称基于原型的聚类

- 假设：聚类结构能通过一组原型刻画
- 过程：对原型进行初始化，然后对原型进行迭代更新求解
- 代表：k均值聚类，学习向量量化(LVQ)，高斯混合聚类

■ 9.4.1 k均值算法

■ 思想

- 样本集 $D=\{\mathbf{x}_1, \dots, \mathbf{x}_m\}$ 聚类所得划分 $C=\{C_1, \dots, C_k\}$ 的最小化平方误差为

$$E = \sum_{i=1}^k \sum_{\mathbf{x} \in C_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|_2^2$$

- $\boldsymbol{\mu}_i = \frac{1}{C_i} \sum_{\mathbf{x} \in C_i} \mathbf{x}$ 是簇的均值向量
- 刻画了簇内样本围绕簇均值向量的紧密程度

9.4 原型聚类

9.4.1 k均值算法


■ 思想

- E值越小则簇内样本相似度越高
- 最小化E值即可求解划分
 - 最优解需考察样本集所有可能的簇划分，是NP难问题
 - 采用了贪心策，通过迭代优化来近似求解

■ 算法

■ 主要步骤

- Step1: 随机选取k个样本点作为簇中心
- Step2: 根据到簇中心距离，将样本点划分给最近的簇
- Step3: 更新各簇的均值向量，将其作为新的簇中心
- Step4: 若所有簇中心未改变，则停止；否则执行Step2



9.4 原型聚类

9.4.1 k均值算法

■ 算法

输入: 样本集 $D = \{x_1, x_2, \dots, x_m\}$;
聚类簇数 k .

过程:

均值向量初始化

1: 从 D 中随机选择 k 个样本作为初始均值向量 $\{\mu_1, \mu_2, \dots, \mu_k\}$

2: **repeat**

3: 令 $C_i = \emptyset$ ($1 \leq i \leq k$)

4: **for** $j = 1, 2, \dots, m$ **do**

5: 计算样本 x_j 与各均值向量 μ_i ($1 \leq i \leq k$) 的距离: $d_{ji} = \|x_j - \mu_i\|_2$;

当前簇划分

6: 根据距离最近的均值向量确定 x_j 的簇标记: $\lambda_j = \arg \min_{i \in \{1, 2, \dots, k\}} d_{ji}$;

7: 将样本 x_j 划入相应的簇: $C_{\lambda_j} = C_{\lambda_j} \cup \{x_j\}$;

8: **end for**

9: **for** $i = 1, 2, \dots, k$ **do**

10: 计算新均值向量: $\mu'_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$;

簇均值向量更新

11: **if** $\mu'_i \neq \mu_i$ **then**

12: 将当前均值向量 μ_i 更新为 μ'_i

13: **else**

14: 保持当前均值向量不变

15: **end if**

16: **end for**

17: **until** 当前均值向量均未更新

簇划分结果返回

输出: 簇划分 $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$

9.4 原型聚类

9.4.1 k均值算法

■ 例




图 9.3 西瓜数据集 4.0 上 k 均值算法($k=3$)在各轮迭代后的结果. 样本点与均值向量分别用“●”与“+”表示, 红色虚线显示出簇划分.

9.4 原型聚类

9.4.2 学习向量量化LVQ

- 试图找到一组原型向量来刻画聚类结构，但假设数据样本带有类别标记
 - 利用样本的监督信息来辅助聚类
 - 实际是通过聚类来形成类别的子类结构，每个子类对应一个聚类簇
- 算法
 - 符号表示
 - 样本集 $D = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_m, y_m)\}$
 - 样本 $\mathbf{x}_j = (x_{j1}; \dots; x_{jn})$
 - 样本 $\mathbf{x}_j$ 的类别标记 $y_j \in Y$
 - 一组原型向量 $\{\mathbf{p}_1, \dots, \mathbf{p}_q\}$
 - 每个原型向量代表一个聚类簇，簇标记 $t_i \in Y$

9.4 原型聚类

9.4.2 学习向量量化LVQ

■ 算法

输入: 样本集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
原型向量个数 q , 各原型向量预设的类别标记 $\{t_1, t_2, \dots, t_q\}$;
学习率 $\eta \in (0, 1)$.

过程:

- 1: 初始化一组原型向量 $\{\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_q\}$
 - 2: repeat
 - 3: 从样本集 D 随机选取样本 $(\mathbf{x}_j, y_j)$;
 - 4: 计算样本 $\mathbf{x}_j$ 与 $\mathbf{p}_i$ ($1 \leq i \leq q$) 的距离: $d_{ji} = \|\mathbf{x}_j - \mathbf{p}_i\|_2$;
 - 5: 找出与 $\mathbf{x}_j$ 距离最近的原型向量 $\mathbf{p}_{i^*}$, $i^* = \arg \min_{i \in \{1, 2, \dots, q\}} d_{ji}$;
 - 6: if $y_j = t_{i^*}$ then
 - 7: $\mathbf{p}' = \mathbf{p}_{i^*} + \eta \cdot (\mathbf{x}_j - \mathbf{p}_{i^*})$ 类别相同, $\mathbf{p}'$ 靠近 $\mathbf{x}_j$
 $\|\mathbf{p}' - \mathbf{x}_j\|_2 = \|\mathbf{p}_{i^*} + \eta(\mathbf{x}_j - \mathbf{p}_{i^*}) - \mathbf{x}_j\|_2 = (1 - \eta)\|\mathbf{p}_{i^*} - \mathbf{x}_j\|_2$
 - 8: else
 - 9: $\mathbf{p}' = \mathbf{p}_{i^*} - \eta \cdot (\mathbf{x}_j - \mathbf{p}_{i^*})$ 类别不同, $\mathbf{p}'$ 远离 $\mathbf{x}_j$
 $\|\mathbf{p}' - \mathbf{x}_j\|_2 = \|\mathbf{p}_{i^*} - \eta(\mathbf{x}_j - \mathbf{p}_{i^*}) - \mathbf{x}_j\|_2 = (1 + \eta)\|\mathbf{p}_{i^*} - \mathbf{x}_j\|_2$
 - 10: end if
 - 11: 将原型向量 $\mathbf{p}_{i^*}$ 更新为 $\mathbf{p}'$
 - 12: until 满足停止条件
- 输出: 原型向量 $\{\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_q\}$

9.4 原型聚类

9.4.2 学习向量量化LVQ

■ 算法

- 学得一组原型向量，即可实现对样本空间 X 的簇划分，样本被划入与其距离最近的原型向量所代表的簇中
- 实际上每个原型向量定义了一个区域，区域中每个样本与它的距离不大于与其他原型向量的距离，即 $R_i = \{x \in X \mid \|x - p_i\|_2 \leq \|x - p_{i'}\|_2, i' \neq i\}$
- 这样的划分常称为Voronoi 剖分




图 9.5 西瓜数据集 4.0 上 LVQ 算法($q=5$)在不同轮数迭代后的聚类结果. c_1 , c_2 类样本点与原型向量分别用“●”, “○”与“+”表示, 红色虚线显示出聚类形成的 Voronoi 剖分.

9.4 原型聚类

9.4.3 高斯混合聚类

- 采用概率模型来表达聚类原型

- 高斯分布

- n 维样本空间中的随机向量 $\mathbf{x}$ 若服从高斯分布，其概率密度函数为

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{x}-\mu)^T \Sigma^{-1}(\mathbf{x}-\mu)}$$

- μ 是 n 维均值向量， Σ 是协方差矩阵，确定高斯分布
 - 这种依赖关系记为 $p(\mathbf{x}|\mu, \Sigma)$

- 高斯混合分布

- 分布由 k 个成分组成，每个成分对应一个高斯分布

$$p_M(\mathbf{x}) = \sum_{i=1}^k \alpha_i p(\mathbf{x}|\mu_i, \Sigma_i)$$

- 混合系数 $\alpha_i > 0, \sum_{i=1}^k \alpha_i = 1$

9.4 原型聚类

9.4.3 高斯混合聚类

■ 思想

- 假设样本的生成过程由高斯混合分布给出
 - 首先选择高斯混合成分，其中 α_i 为选择第 i 个混合成分的概率
 - 然后根据被选择的混合成分的概率密度函数进行采样
 - 令随机变量 $z_j \in \{1, \dots, k\}$ 表示生成样本 $\mathbf{x}_j$ 的高斯混合成分， z_j 的先验概率 $P(z_j=i)$ 对应于 α_i ，则 z_j 的后验分布

$$p_M(z_j=i|\mathbf{x}_j) = \frac{P(z_j=i)p_M(\mathbf{x}_j|z_j=i)}{p_M(\mathbf{x}_j)} = \frac{\alpha_i p(\mathbf{x}_j|\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)}{\sum_{l=1}^k \alpha_l p(\mathbf{x}_j|\boldsymbol{\mu}_l, \boldsymbol{\Sigma}_l)} \stackrel{\text{记}}{=} \gamma_{ji}$$

- 样本集 D 划分为 k 个簇 $C=\{C_1, \dots, C_k\}$ ，每个样本 $\mathbf{x}_j$ 的簇标记 λ_j 为

$$\lambda_j = \operatorname{argmax}_{i \in \{1, \dots, k\}} \gamma_{ji}$$

9.4 原型聚类

9.4.3 高斯混合聚类

■ 思想

- 求解(极大似然估计, 最大化对数似然)

- 对数似然

$$LL(D) = \sum_{j=1}^m \ln \left(\sum_{i=1}^k \alpha_i p(\mathbf{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \right)$$

- 令导数为0可得

$$\boldsymbol{\mu}_i = \sum_{j=1}^m \gamma_{ji} \mathbf{x}_j / \sum_{j=1}^m \gamma_{ji}$$

$$\boldsymbol{\Sigma}_i = \sum_{j=1}^m \gamma_{ji} (\mathbf{x}_j - \boldsymbol{\mu}_i)(\mathbf{x}_j - \boldsymbol{\mu}_i)^T / \sum_{j=1}^m \gamma_{ji}$$

- 引入拉格朗日乘子得

$$\alpha_i = \frac{1}{m} \sum_{j=1}^m \gamma_{ji}$$

- 用EM算法

- (E步) 根据当前参数计算每个样本属于每个高斯成分的后验概率 γ_{ji}
- (M步) 更新模型参数 $\{(\alpha_i, \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) | 1 \leq i \leq k\}$

9.4 原型聚类

9.4.3 高斯混合聚类

■ 算法

输入: 样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;
高斯混合成分个数 k .

过程:

- 1: 初始化高斯混合分布的模型参数 $\{(\alpha_i, \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \mid 1 \leq i \leq k\}$
 - 2: repeat
 - 3: for $j = 1, 2, \dots, m$ do
 - 4: 根据式(9.30)计算 $\mathbf{x}_j$ 由各混合成分生成的后验概率, 即
 $\gamma_{ji} = p_{\mathcal{M}}(z_j = i \mid \mathbf{x}_j) \ (1 \leq i \leq k)$
 - 5: end for
 - 6: for $i = 1, 2, \dots, k$ do
 - 7: 计算新均值向量: $\boldsymbol{\mu}'_i = \frac{\sum_{j=1}^m \gamma_{ji} \mathbf{x}_j}{\sum_{j=1}^m \gamma_{ji}}$;
 - 8: 计算新协方差矩阵: $\boldsymbol{\Sigma}'_i = \frac{\sum_{j=1}^m \gamma_{ji} (\mathbf{x}_j - \boldsymbol{\mu}'_i)(\mathbf{x}_j - \boldsymbol{\mu}'_i)^T}{\sum_{j=1}^m \gamma_{ji}}$;
 - 9: 计算新混合系数: $\alpha'_i = \frac{\sum_{j=1}^m \gamma_{ji}}{m}$;
 - 10: end for
 - 11: 将模型参数 $\{(\alpha_i, \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \mid 1 \leq i \leq k\}$ 更新为 $\{(\alpha'_i, \boldsymbol{\mu}'_i, \boldsymbol{\Sigma}'_i) \mid 1 \leq i \leq k\}$
 - 12: until 满足停止条件
 - 13: $C_i = \emptyset \ (1 \leq i \leq k)$
 - 14: for $j = 1, 2, \dots, m$ do
 - 15: 根据式(9.31)确定 $\mathbf{x}_j$ 的簇标记 λ_j ;
 - 16: 将 $\mathbf{x}_j$ 划入相应的簇: $C_{\lambda_j} = C_{\lambda_j} \cup \{\mathbf{x}_j\}$
 - 17: end for
- 输出: 簇划分 $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$

9.4 原型聚类

9.4.3 高斯混合聚类




图 9.7 高斯混合聚类($k=3$)在不同轮数迭代后的聚类结果. 其中样本簇 C_1 , C_2 与 C_3 中的样本点分别用“o”, “■”与“▲”表示, 各高斯混合成分的均值向量用“+”表示.

9.5 密度聚类

■ 亦称基于密度的聚类

- 假设：聚类结构能通过样本分布的紧密程度确定
- 过程：从样本密度的角度来考察样本间的可连接性，并基于可连接样本不断扩展聚类簇
- 代表：DBSCAN、OPTICS、DENCLUE

■ DBSCAN

- 基于一组邻域参数刻画样本分布的紧密程度
- 关键概念
 - ε -邻域：包含样本集 D 中与 $\mathbf{x}_j$ 的距离不大于 ε 的样本，即 $N_\varepsilon(\mathbf{x}_j) = \{\mathbf{x}_i \in D \mid \text{dist}(\mathbf{x}_i, \mathbf{x}_j) \leq \varepsilon\}$
 - 核心对象：若 $\mathbf{x}_j$ 的 ε 邻域至少包含 $MinPts$ 个样本，即 $|N_\varepsilon(\mathbf{x}_j)| \geq MinPts$ ，则 $\mathbf{x}_j$ 是一个核心对象

9.5 密度聚类


DBSCAN

■ 关键概念

- 密度直达：若 x_j 位于 x_i 的 ε -邻域中，且 x_i 是核心对象，则称 x_j 由 x_i 密度直达
 - 不满足对称性
- 密度可达：对 x_i, x_j 若存在样本序列 $p_1, \dots, p_n, p_1 = x_i, p_n = x_j$ 且 p_{i+1} 由 p_i 密度直达，则 x_j 由 x_i 密度可达
 - 满足直递性，不满足对称性
- 密度相连：对 x_i, x_j 若存在 x_k 使得 x_i, x_j 均由 x_k 可达，则 x_i, x_j 密度相连
 - 满足对称

令 $MinPts = 3$,
虚线显示出 ε 邻域
 x_1 是核心对象

x_2 由 x_1 密度直达
 x_3 由 x_1 密度可达
 x_3 与 x_4 密度相连



9.5 密度聚类

■ DBSCAN

■ 思想

- 将簇定义为由密度可达关系导出的最大的密度相连样本集合
 - 给定邻域参数 $(\varepsilon, MinPts)$ ，簇 $C \subseteq D$ 满足以下条件
 - 连接性: $x_i \in C, x_j \in C \Rightarrow x_i, x_j$ 密度相连
 - 最大性: $x_i \in C, x_j$ 由 x_i 密度可达 $\Rightarrow x_j \in C$
 - 不属于任何簇的样本认为是噪声或异常样本
- 如何从数据集D中找出满足以上性质的聚类簇
 - 若 x 为核心对象，由 x 密度可达的所有样本组成的集合一定满足连接性与最大性
 - 任选数据集中的核心对象为种子，由此出发确定相应的聚类簇

9.5 密度聚类

DBSCAN

■ 算法

输入: 样本集 $D = \{x_1, x_2, \dots, x_m\}$;
邻域参数 $(\epsilon, MinPts)$.

过程:

```
1: 初始化核心对象集合:  $\Omega = \emptyset$ 
2: for  $j = 1, 2, \dots, m$  do
3:   确定样本  $x_j$  的  $\epsilon$ -邻域  $N_\epsilon(x_j)$ ;
4:   if  $|N_\epsilon(x_j)| \geq MinPts$  then
5:     将样本  $x_j$  加入核心对象集合:  $\Omega = \Omega \cup \{x_j\}$ 
6:   end if
7: end for
8: 初始化聚类簇数:  $k = 0$ 
9: 初始化未访问样本集合:  $\Gamma = D$ 
10: while  $\Omega \neq \emptyset$  do
11:   记录当前未访问样本集合:  $\Gamma_{old} = \Gamma$ ;
12:   随机选取一个核心对象  $o \in \Omega$ , 初始化队列  $Q = \langle o \rangle$ ;
13:    $\Gamma = \Gamma \setminus \{o\}$ ;
14:   while  $Q \neq \emptyset$  do
15:     取出队列  $Q$  中的首个样本  $q$ ;
16:     if  $|N_\epsilon(q)| \geq MinPts$  then
17:       令  $\Delta = N_\epsilon(q) \cap \Gamma$ ;
18:       将  $\Delta$  中的样本加入队列  $Q$ ;
19:        $\Gamma = \Gamma \setminus \Delta$ ;
20:     end if
21:   end while
22:    $k = k + 1$ , 生成聚类簇  $C_k = \Gamma_{old} \setminus \Gamma$ ;
23:    $\Omega = \Omega \setminus C_k$ 
24: end while

输出: 簇划分  $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$ 
```

9.5 密度聚类

DBSCAN

例子




图 9.10 DBSCAN 算法($\epsilon = 0.11$, $MinPts = 5$)生成聚类簇的先后情况, 核心对象、非核心对象、噪声样本分别用“●” “○” “*”表示, 红色虚线显示出簇划分。

9.6 层次聚类

■ 特点

- 假设：能够产生不同粒度的聚类结果
- 过程：试图在不同层次对数据集进行划分，从而形成树形的聚类结构
- 代表：AGNES（自底向上聚合策略），DIANA（自顶向下分拆策略）

■ AGNES

■ 思想

- 将每个样本看作一个初始聚类簇
- 每一步中找出距离最近的两个聚类簇进行合并
- 不断重复，直至达到预设的聚类簇个数
- 关键问题是如何计算聚类簇之间的距离

9.6 层次聚类

■ AGNES

■ 思想

■ 聚类簇之间的距离计算

- 最小距离: $d_{\min}(C_i, C_j) = \min_{x \in C_i, z \in C_j} \text{dist}(x, z)$

- 由两个簇的最近样本决定

- 最大距离: $d_{\max}(C_i, C_j) = \max_{x \in C_i, z \in C_j} \text{dist}(x, z)$

- 由两个簇的最远样本决定

- 平均距离: $d_{\text{avg}}(C_i, C_j) = \frac{1}{|C_i||C_j|} \sum_{x \in C_i} \sum_{z \in C_j} \text{dist}(x, z)$

- 由两个簇的所有样本共同决定

相应的单
链接算法

相应的全链接
或均链接算法

- 当聚类簇距离由最小距离、最大距离、平均距离计算时，AGNES算法被相应地称为单链接(single-linkage)，全链接(complete-linkage)或均链接(average-linkage)算法

9.6 层次聚类

■ AGNES

■ 算法流程

输入: 样本集 $D = \{x_1, x_2, \dots, x_m\}$;
聚类簇距离度量函数 d ;
聚类簇数 k .

过程:

```
1: for  $j = 1, 2, \dots, m$  do
2:    $C_j = \{x_j\}$   初始化单样本聚类簇
3: end for
4: for  $i = 1, 2, \dots, m$  do
5:   for  $j = 1, 2, \dots, m$  do
6:      $M(i, j) = d(C_i, C_j)$ ;  初始化聚类
7:      $M(j, i) = M(i, j)$       簇距离矩阵
8:   end for
9: end for
```

```
10: 设置当前聚类簇个数:  $q = m$ 
11: while  $q > k$  do
12:   找出距离最近的两个聚类簇  $C_{i^*}$  和  $C_{j^*}$ ;
13:   合并  $C_{i^*}$  和  $C_{j^*}$ :  $C_{i^*} = C_{i^*} \cup C_{j^*}$ ;
14:   for  $j = j^* + 1, j^* + 2, \dots, q$  do
15:     将聚类簇  $C_j$  重编号为  $C_{j-1}$ 
16:   end for
17:   删除距离矩阵  $M$  的第  $j^*$  行与第  $j^*$  列;
18:   for  $j = 1, 2, \dots, q - 1$  do
19:      $M(i^*, j) = d(C_{i^*}, C_j)$ ;
20:      $M(j, i^*) = M(i^*, j)$ 
21:   end for
22:    $q = q - 1$ 
23: end while
输出: 簇划分  $C = \{C_1, C_2, \dots, C_k\}$ 
```

9.6 层次聚类

■ AGNES

■ 例子





图 9.12 西瓜数据集 4.0 上 AGNES 算法生成的树状图(采用 $d_{\max}$). 横轴对应于样本编号, 纵轴对应于聚类簇距离。


9.6 层次聚类

AGNES


■ 例子




(a) 聚类簇数 $k=7$



(b) 聚类簇数 $k=6$




(c) 聚类簇数 $k=5$



(d) 聚类簇数 $k=4$

图 9.13 西瓜数据集 4.0 上 AGNES 算法(采用 $d_{\max}$)在不同聚类簇数($k=7, 6, 5, 4$)时的簇划分结果. 样本点用“●”表示, 红色虚线显示出簇划分.



作业
