

计算机视觉

课程内容总结

软件学院：刘春

第一章 绪论

- 1.什么是计算机视觉？
- 2.计算机视觉的主要应用？
- 3.计算机视觉发展历程

什么是计算机视觉？

- 百度百科

计算机视觉是一门研究如何使机器“看”的科学，更进一步的说，就是指用摄影机和电脑代替人眼对目标进行识别、跟踪和测量等机器视觉，并进一步做图形处理，使电脑处理成为更适合人眼观察或传送给仪器检测的图像。

作为一个科学学科，计算机视觉研究相关的理论和技术，试图建立能够从图像或者多维数据中获取‘信息’的人工智能系统。

计算机视觉的主要应用

- 3D建模
- 地图映射
- 计算摄影
- 手写字符识别
- 人脸检测
- 物体识别
- 生物视觉识别
- 目标识别
- 动画3D建模
- AR/VR
- 自动驾驶
- 全景拼接
- 机器自主导航
- 工业视觉
- ...

课程目标


- 1. 图像形成的基本原理
- 2. 图像分析基础
 - 卷积与图像金字塔
 - 图像局部特征分析
- 3. 基于深度学习的图像分析
 - 深度学习与图像分类
 - 图像分割
 - 目标检测与识别
 - 图像生成
- 4. 视觉分析
 - 图像全景拼接与配准
 - 光流与运动估计
 - 双目视觉原理

第二章 图像形成

- 针孔相机模型
- 几何模型
 - 内部参数
 - 外部参数

2.1 针孔相机

- 三维世界至二维图像平面投影



2.3 几何模型


- 透视投影基本方程矩阵表示:

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1/f' & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} = \begin{bmatrix} x \\ y \\ z/f' \end{bmatrix} \Rightarrow \left(f' \frac{x}{z}, f' \frac{y}{z} \right)$$

齐次坐标除以z坐标
转换成非齐次坐标

2.3 几何模型-内部参数

相机
矩阵




$$P' = M P$$

$$= K \begin{bmatrix} I & 0 \end{bmatrix} P$$

Camera matrix K

$$P' = \begin{bmatrix} \alpha & 0 & c_x & 0 \\ 0 & \beta & c_y & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$

2.3 几何模型-外部参数



- 4D齐次坐标:

$$P = \begin{bmatrix} R & T \\ 0 & 1 \end{bmatrix}_{4 \times 4} P_w \quad P_w \leftarrow \begin{bmatrix} x_w \\ y_w \\ z_w \\ 1 \end{bmatrix}$$

Internal parameters

External parameters


$$P' = K \begin{bmatrix} I & 0 \end{bmatrix} P = K \begin{bmatrix} I & 0 \end{bmatrix} \begin{bmatrix} R & T \\ 0 & 1 \end{bmatrix}_{4 \times 4} P_w = \underbrace{K}_{\mathbf{M}} \underbrace{\begin{bmatrix} R & T \end{bmatrix}}_{\text{External parameters}} P_w \quad [\text{Eq.11}]$$

第三章 图像滤波与边缘检测

- 数字图像的表达
 - 二维函数
 - 二维至一维映射
- 图像基本操作
 - 点操作
 - 局部区域操作
 - 全局操作
- 滤波与卷积
 - 噪声类型
 - 高斯滤波器
 - 滤波核参数
 - 卷积
 - 边界效应
- 模板匹配
 - 相关运算
- 边缘检测
 - 边缘定义
 - 边缘检测步骤
 - 梯度检测子
 - 高斯拉普拉斯检测子
 - Canny检测子

3.3 图像滤波


- 如何设置滤波核 H 的值?



$$G = H \otimes F$$


3.3 图像滤波—高斯滤波

- 需要设置哪些参数?
- 内核或掩膜大小
 - 注意：高斯函数有无限支撑集，但是离散滤波支撑集有限



$\sigma = 5$

10 x 10 内核




$\sigma = 5$


30 x 30 内核

3.3 图像滤波—高斯滤波

- 需要设置哪些参数?
- 高斯核方差：平滑的程度





$\sigma = 2$
30 x 30 内核




$\sigma = 5$
30 x 30 内核

3.3 图像滤波—高斯滤波

高斯滤波核参数 σ 的影响




...




```
for sigma=1:3:10
    h = fspecial('gaussian', fsize, sigma);
    out = imfilter(im, h);
    imshow(out);
    pause;
end
```

3.4 模板匹配



场景



模板 (掩膜)


示例

3.5 边缘检测

哪些地方是边缘?

反射率变化:
表面, 纹理

表面方向变化:
形状



深度不连续:
目标边界

投射阴影


3.5 边缘检测

图像的偏导数




$$\frac{\partial f(x, y)}{\partial x}$$

-1	1
----	---



$$\frac{\partial f(x, y)}{\partial y}$$

-1	?	1
1	或	-1



哪一幅是x方向？

3.5 边缘检测—组合检测子

Prewitt: $M_x = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}$; $M_y = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{bmatrix}$

Sobel: $M_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$; $M_y = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$




Roberts: $M_x = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$; $M_y = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$

3.5 边缘检测— 图像梯度

图像的梯度:

$$\nabla f = \left[\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right]$$

梯度方向为强度变化最剧烈的方向



边缘方向为梯度方向，可以表示为:

$$\theta = \tan^{-1} \left(\frac{\partial f / \partial y}{\partial f / \partial x} \right)$$

边缘强度为梯度幅值:


$$\|\nabla f\| = \sqrt{\left(\frac{\partial f}{\partial x} \right)^2 + \left(\frac{\partial f}{\partial y} \right)^2}$$

3.5 边缘检测—噪声影响


考虑行或列单一方向

— 图像强度函数

$f(x)$




$\frac{d}{dx}f(x)$




边缘在哪里？

3.5 边缘检测—Gaussian-Laplace检测子




高斯核

$$h_{\sigma}(u, v) = \frac{1}{2\pi\sigma^2} e^{-\frac{u^2+v^2}{2\sigma^2}}$$



高斯核导数

$$\frac{\partial}{\partial x} h_{\sigma}(u, v)$$



高斯-拉普拉斯

$$\nabla^2 h_{\sigma}(u, v)$$

- ∇^2 为laplace检测子:

$$\nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

3.5 边缘检测

检测子特性

- 平滑
 - 值为正
 - 和为1
 - 平滑程度正比于掩膜大小
 - 减少高频成分
- 导数
 - 相反符号以便在边缘处获得高响应值
 - 和为0
 - 边缘点值大
- 模板匹配
 - 在模板相似区域响应值高
 - 相关计算

3.5 边缘检测—Canny检测子

- 使用高斯检测子计算
- 确定梯度幅值和方向
- 非最大化抑制：
多像素宽度窄带边缘细化为单像素宽度
- 边缘阈值和连接 (滞后法):
 - 定义双阈值：低和高
 - 高阈值确定边缘起始，低阈值进行边缘连接

3.5 边缘检测—性能评估

- 混淆矩阵

	标签正向	标签负向
检测结果正向	tp	fp
检测结果负向	fn	tn

3.5 边缘检测—性能评估

- **精确率**：检测结果正向中正确像素的比率

$$P = \frac{tp}{tp + fp}$$

- **召回率**：标签为边缘像素中被正确检测的比率

$$R = \frac{tp}{tp + fn}$$


	标签正向	标签负向
检测结果正向	tp	fp
检测结果负向	fn	tn

第四章-局部特征提取


- Harris角点检测
 - 角点的定义
 - Harris角点检测子
 - Harris角点的不变特性
- 局部区域描述
 - 方向直方图描述子
 - 旋转不变性
- 特征匹配
 - SSD距离
 - 比值SSD距离
 - 参数变换
- SIFT算法
 - SIFT算法流程
 - SIFT算法特性

4.2.Harris角点检测


- 通过一个小的邻域窗很容易识别这种点
- 窗口沿着任意方向移动窗口强度都会发生很大的改变



“flat” 区域：
在所有方向移动没有变化



“edge”：
沿着边缘方向移动没有变化



“corner”：
沿着任何方向移动都有显著变化

4.2.Harris角点检测

能量可以近似为:

$$E(u, v) \approx [u \ v] M \begin{bmatrix} u \\ v \end{bmatrix}$$

M 是一个从图像梯度计算的 2×2 矩阵:

$$M = \sum_{x,y} w(x,y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$$

x 方向梯度乘
以 y 方向梯度


在角点的窗口
区域中求和

$$M = \begin{bmatrix} \sum I_x I_x & \sum I_x I_y \\ \sum I_x I_y & \sum I_y I_y \end{bmatrix} = \sum \begin{bmatrix} I_x \\ I_y \end{bmatrix} [I_x \ I_y]$$

4.2.Harris角点检测— 角点响应函数

$$R = \det(M) - \alpha \text{trace}(M)^2 = \lambda_1 \lambda_2 - \alpha(\lambda_1 + \lambda_2)^2$$

α : 常量 (0.04 to 0.06)




4.2.Harris角点检测

- 算法步骤：
 - 计算边缘
 - 设定窗口及权重，计算矩阵 M 得到整个图像的响应值 R
 - 找出具有较大响应值的点 ($R > \text{threshold}$)
 - 确定 R 局部极值



4.3.多尺度空间

- 高斯金字塔
 - 高斯金字塔构建




4.4. 图像匹配






- 1.特征点提取



- 1.特征点提取
- 2.特征点匹配




- 1.特征点提取
- 2.特征点匹配
- 3.匹配特征点筛选



- 1.特征点提取
- 2.特征点匹配
- 3.匹配特征点筛选
- 4.变换参数求解


4.6. SIFT算法

- 高斯金字塔




4.6. SIFT算法

- DoG算子







4.6. SIFT算法

- DoG尺度空间极值点






4.6. SIFT算法

- 特征点尺度
- 特征点主方向



4.6. SIFT算法

- 特征描述



4.6. SIFT算法


- 特征点匹配
- 变换参数求解




第五章-机器学习与图像分类

- 最近邻方法
 - 最近邻分类方法
 - 距离测度
 - 超参数
- 线性分类
 - 线性分类器
 - 线性分类器的三种解释
- 损失函数
 - SVM损失函数
 - 交叉熵损失函数
- 最优化
 - 梯度速降法
 - 随机梯度速降法

最近邻分类




参数化方法：线性分类器



线性分类器: 三个角度

代数角度

$$f(x, W) = Wx$$




可视化角度

每类一个模板




几何角度


超平面切割




二元Logistics回归



多元Logistics回归



多类 SVM 损失



cat	3.2	1.3	2.2
car	5.1	4.9	2.5
frog	-1.7	2.0	-3.1
Loss	2.9		

给定一副图像 (x_i, y_i)
(x_i 为图像, y_i 为标签)


令 $s = f(x_i, W)$ 为响应分值

则SVM 损失定义为:

$$\begin{aligned} L_i &= \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1) \\ &= \max(0, 5.1 - 3.2 + 1) \\ &\quad + \max(0, -1.7 - 3.2 + 1) \\ &= \max(0, 2.9) + \max(0, -3.9) \\ &= 2.9 + 0 \\ &= 2.9 \end{aligned}$$

交叉熵损失(多元Logistic回归)

将分类器输出的分值解释为概率:




$$s = f(x_i; W)$$

$$P(Y = k|X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}} \quad \text{Softmax 函数}$$

概率必须 ≥ 0

概率和为1

$$L_i = -\log P(Y = y_i|X = x_i)$$



最大似然估计
选择权重对应观察数据的最大似然函数

随机梯度速降(SGD)

$$L(W) = \frac{1}{N} \sum_{i=1}^N L_i(x_i, y_i, W) + \lambda R(W)$$

$$\nabla_W L(W) = \frac{1}{N} \sum_{i=1}^N \nabla_W L_i(x_i, y_i, W) + \lambda \nabla_W R(W)$$

当 N 很大时，全部求和代价高！

使用一个很小的批进行求和来近似
通常 32 / 64 / 128

```
# Stochastic gradient descent
w = initialize_weights()
for t in range(num_steps):
    minibatch = sample_data(data, batch_size)
    dw = compute_gradient(loss_fn, minibatch, w)
    w -= learning_rate * dw
```

超参数:

- 权重初始化
- 步数
- 学习率
- 批大小
- 数据采样

第六章-神经网络

- 多层神经网络
 - 线性分类器级联
 - 神经网络的组成
- 激活函数
 - 神经元
 - Sigmoid激活函数
 - 线性修正单元
 - Softmax函数
- 神经网络的训练
 - 后向传播算法

神经网络

(前面) 线性响应函数:


$$f = Wx$$

(现在) 2-层神经网络

$$f = W_2 \max(0, W_1 x)$$

W_1 元素 (i, j) 给出了 x_j 对 h_i 的影响

x 的所有元素影响 h 的所有元素



W_2 元素 (i, j) 给出了 h_j 对 s_i 影响


h 的所有元素影响 s 的所有元素

全连接神经网络
也称为“多层感知器” (MLP)

激活函数

2-层神经网络


函数 $ReLU(z) = \max(0, z)$ 被称为
“修正线性单元(Rectified Linear Unit)”



$$f = W_2 \max(0, W_1 x)$$

被称为神经网络的激活函数

深度神经网络



$$s = W_6 \max(0, W_6 \max(0, W_5 \max(0, W_4 \max(0, W_3 \max(0, W_2 \max(0, W_1 x))))))$$

后向传播算法: 举例

$$f(x, y, z) = (x + y)z$$


e.g. $x = -2, y = 5, z = -4$

1. 前向传递: 计算输出

$$q = x + y \quad f = qz$$

2. 后向传递: 计算导数

想计算: $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}$



链式法则

$$\frac{\partial f}{\partial x} = \frac{\partial q}{\partial x} \frac{\partial f}{\partial q}$$


$$\frac{\partial q}{\partial x} = 1$$

下游梯度 局部梯度 上游梯度

另一个示例


$$f(x, w) = \frac{1}{1 + e^{-(w_0x_0 + w_1x_1 + w_2)}} = \sigma(w_0x_0 + w_1x_1 + w_2)$$

后向传递: 计算梯度



$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

计算图不唯一: 可以使用简单梯度的基本单元



[下游] = [当前] * [上游]

$$= (1 - 0.73) * 0.73 * 1.0 = 0.2$$

Sigmoid local gradient:

$$\frac{\partial}{\partial x} [\sigma(x)] = \frac{e^{-x}}{(1 + e^{-x})^2} = \left(\frac{1 + e^{-x} - 1}{1 + e^{-x}} \right) \left(\frac{1}{1 + e^{-x}} \right) = (1 - \sigma(x))\sigma(x)$$


第六章-卷积神经网络

- 卷积神经网络的成分
 - 卷积网络目的
 - 卷积网络组成
- 卷积层
 - 卷积参数
 - 感受野
- 池化
 - 池化参数
- 卷积神经网络的训练
 - 数据增强
 - 正则化
 - Dropout
 - 学习速率

卷积网络LeNet-5


经典结构: [Conv, ReLU, Pool] x N, flatten, [FC, ReLU] x N, FC

举例: LeNet-5




Lecun et al, "Gradient-based learning applied to document recognition", 1998

卷积层 Convolution Layer



感受野

每个连续卷积加上 $K-1$ 到感受野之中
 L 层的感受野共 $1 + L * (K - 1)$




输入

问题: 对于大图像, 需要多层使得每个输出能够“看到”整个图像

方案: 下采样

输出

卷积步长



输入: 7x7

滤波: 3x3

步长: 2

输出: 3x3

通常:

输入: W

滤波: K

填充: P

步长: S

输出: $(W - K + 2P) / S + 1$

卷积总结

输入: $C_{in} \times H \times W$

超参数:

- 核大小: $K_H \times K_W$
- 核数量: C_{out}
- 填充: P
- 步长: S

权重矩阵: $C_{out} \times C_{in} \times K_H \times K_W$ 个
大小为 $C_{in} \times K_H \times K_W$ 滤波核

偏置向量: C_{out}

输出大小: $C_{out} \times H' \times W'$ 这里:

- $H' = (H - K + 2P) / S + 1$
- $W' = (W - K + 2P) / S + 1$

常用设置:

$K_H = K_W$ (等尺寸滤波核)

$P = (K - 1) / 2$ ("相同尺寸" 填充)

$C_{in}, C_{out} = 32, 64, 128, 256$ (2的幂次方)

$K = 3, P = 1, S = 1$ (3x3 conv)

$K = 5, P = 2, S = 1$ (5x5 conv)

$K = 1, P = 0, S = 1$ (1x1 conv)

$K = 3, P = 1, S = 2$ (2倍下采样)

卷积举例

输入: **3** x 32 x 32


10 **5x5** 滤波组步长1, 填充2

输出大小: **10 x 32 x 32**


学习参数规模: 760

乘法次数: **768,000**

10*32*32 = 10,240 输出; 每个输出是两个 **3x5x5** 张量 (75 个元素) 的点积; 总计 = $75 * 10240 = 768K$




最大池化



举例: LeNet-5

Layer	Output Size	Weight Size
Input	1 x 28 x 28	
Conv ($C_{out}=20$, $K=5$, $P=2$, $S=1$)	20 x 28 x 28	20 x 1 x 5 x 5
ReLU	20 x 28 x 28	
MaxPool($K=2$, $S=2$)	20 x 14 x 14	
Conv ($C_{out}=50$, $K=5$, $P=2$, $S=1$)	50 x 14 x 14	50 x 20 x 5 x 5
ReLU	50 x 14 x 14	
MaxPool($K=2$, $S=2$)	50 x 7 x 7	
Flatten	2450	
Linear (2450 -> 500)	500	2450 x 500
ReLU	500	
Linear (500 -> 10)	10	500 x 10



经过整个网络:

空域大小**递减**
(通过池化和带步长的卷积)

通道数**递增**
(整个“体积” 不变!)

Lecun et al, "Gradient-based learning applied to document recognition", 1998

第七章-第九章

图像分类、语义分割、目标检测


图像分类



CAT

No spatial extent


图像语义分割



GRASS, CAT, TREE,
SKY

No objects, just pixels


目标检测



DOG, DOG, CAT

Multiple Objects

实例分割



DOG, DOG, CAT

[This image is CC0 public domain](#)

第七章-第九章

图像分类、语义分割、目标检测

- 图像分类
 - 定义
 - 基本步骤
- 语义分割
 - 定义
 - 基本步骤
- 目标检测
 - 定义
 - 基本步骤

图像分类



[This image is CC0 public domain](#)




Figure copyright Alex Krizhevsky, Ilya Sutskever, and Geoffrey Hinton, 2012. Reproduced with permission.

向量:
4096

全连接:
4096 to 1000

类别分值

Cat: 0.9

Dog: 0.05

Car: 0.01

...

图像分类

经典的卷积神经网络分类架构

AlexNet

VGG

GoogleNet

ResNet


等

目标检测

骨干网络
(Transfer learning)



[This image is CC0 public domain](#)



将定位看成回归问题!

Vector:
4096

Fully
Connected:
4096 to 1000

“类别”

Class Scores

Cat: 0.9
Dog: 0.05
Car: 0.01
...

Correct label:

Cat

**Softmax
Loss**

Multitask
Loss

**Weighted
Sum**

Loss

Fully
Connected:
4096 to 4


**Box
Coordinates**
(x, y, w, h)

“位置”

L2 Loss

Correct box:
(x', y', w', h')

R-CNN: 测试



输入: 单RGB图像

1. 运行候选区域算法获取~2000 候选区域
2. 伸缩每个区域到224x224 并各自独立的经过CNN 预测类别分值和 bbox 变换参数
3. 根据分值选择候选区域输出
(选择方法: 阈值, 或按类别? 或取最大的 K 候选区域?)
4. 与真实分布框比较

Girshick et al, "Rich feature hierarchies for accurate object detection and semantic segmentation", CVPR 2014.
Figure copyright Ross Girshick, 2015; [source](#). Reproduced with permission.

检测框比较: 交叠率Intersection over Union (IoU)

如何计算检测边框和真实边框差异?

Intersection over Union (IoU)
(也称为“Jaccard 相似系数” or
“Jaccard 指数”):

$$\frac{\text{相交的面积}}{\text{合并的面积}}$$

IoU > 0.5是可接受的,
IoU > 0.7是足够好的,
IoU > 0.9是几乎完美的



[Puppy image](#) is licensed under [CC-A 2.0 Generic license](#). Bounding boxes and text added by Justin Johnson.


重叠框: 非最大化抑制(NMS)

问题: 目标检测子经常出现许多重叠结果:

方案: 对粗检测结果进行非最大化抑制(NMS)

1. 选择下一个高分值边框
2. 去除IoU>阈值(e.g. 0.7)的低分值边框
3. 如果仍然存在满足条件的边框, GOTO 1

$$\text{IoU}(\text{■}, \text{■}) = 0.74$$



Puppy image is CC0 Public Domain

目标检测子评估: 均值平均精确率 Mean Average Precision (mAP)


1. 对所有测试图像进行目标检测 (带NMS)
2. 对每个类别, 计算平均精确率(AP) = PR曲线下的面积
 1. 对于每次检测 (从高分值到低分值)
 1. 如果其与某个GT边框 $\text{IoU} > 0.5$, 标记其为正并且抑制这个GT
 2. 否则, 标记其为负
 3. 在PR曲线下画一个点
 2. 平均精确率(AP) = PR曲线下的面积

如何得到 $\text{AP} = 1.0$: 对于所有 $\text{IoU} > 0.5$ 的GT边框, 没有“虚警” 分值高于“正确结果”

狗类别所有检测结果分值由高到低



狗类别所有真实边框



目标检测子评估: 均值平均精确率 Mean Average Precision (mAP)

1. 对所有测试图像进行目标检测 (带NMS)
2. 对每个类别, 计算平均精确率(AP) = PR曲线下的面积
 1. 对于每次检测 (从高分值到低分值)
 1. 如果其与某个GT边框 $\text{IoU} > 0.5$, 标记其为正并且抑制这个GT
 2. 否则, 标记其为负
 3. 在PR曲线下画一个点
 2. 平均精确率(AP) = PR曲线下的面积
3. 均值平均精确率(mAP) = 平均各个类别的AP
4. 对于 “COCO mAP”: 在不同的IoU阈值(0.5, 0.55, 0.6, ..., 0.95)下分别计算 mAP@thresh 并取平均

$$\text{mAP@0.5} = 0.77$$

$$\text{mAP@0.55} = 0.71$$

$$\text{mAP@0.60} = 0.65$$


...

$$\text{mAP@0.95} = 0.2$$


$$\text{COCO mAP} = 0.4$$

Fast R-CNN vs “Slow” R-CNN

Fast R-CNN: 使用可微的裁剪处理全局图像特征



“Slow” R-CNN: 每个候选区域独立CNN处理



Faster R-CNN:可学习的候选区域方法


Faster R-CNN 是一个
两步目标检测子

第一步: 每张图片执行一次

- 骨干网络
- 区域候选网络

第二步: 每个区域执行一次

- 特征裁剪: RoI 池化 / 对齐
- 预测目标类别
- 预测bbox偏移



区域分割定义

- 令集合 R 代表整个图像区域，对 R 的分割可看作将 R 分成若干个满足以下条件的非空子集（子区域） $R_1, R_2, R_3, \dots, R_n$:

$$(1) \bigcup_{i=1}^n R_i$$


(2) 对所有的 i 和 $j, i \neq j$, 有 $R_i \cap R_j = \phi$

(3) 对 $i = 1, 2, \dots, n$, 有 $P(R_i) = \text{true}$

(4) 对 $i \neq j$, 有 $P(R_i \cup R_j) = \text{false}$

(5) 对 $i = 1, 2, \dots, n$, R_i 是连通的区域

语义分割: 滑动窗口




Farabet et al, "Learning Hierarchical Features for Scene Labeling," TPAMI 2013

Pinheiro and Collobert, "Recurrent Convolutional Neural Networks for Scene Labeling", ICML 2014

语义分割: 全卷积网络

编译码模型



Long, Shelhamer, and Darrell, "Fully Convolutional Networks for Semantic Segmentation", CVPR 2015
Noh et al, "Learning Deconvolution Network for Semantic Segmentation", ICCV 2015

计算机视觉

第9章 图像生成


软件学院: 刘春

Ref: C280, Computer Vision
Prof. Trevor Darrell

生成对抗网络 (GAN)

- 什么是生成对抗网络?

生成 对抗 网络



生成对抗网络


- 定义一个纳什均衡目标函数进行联合训练

$$\min_G \max_D \left(E_{x \sim p_{data}} [\log D(x)] + E_{z \sim p(z)} \left[\log \left(1 - D(G(z)) \right) \right] \right)$$

鉴别器希望对于真实数据 $D(x)=1$

鉴别器希望对于生成数据 $D(x)=0$

生成器希望对于生成数据 $D(x)=1$



祝顺利通过考试！
谢谢大家！