

计算机视觉

第8章 图像分割

软件学院：刘春

Ref: C280, Computer Vision
Prof. Trevor Darrell

本章内容

- 8.1.分割定义
- 8.2.区域分割
- 8.3.语义分割
- 8.4.实例分割

计算机视觉任务


分类



猫

不考虑空域内容


语义分割



草地, 猫, 树, 天空

没有目标, 针对像素

目标检测



狗, 狗, 猫

多个目标

实例分割



狗, 狗, 猫

[This image is CC0 public domain](#)

计算机视觉任务：语义分割

Classification


语义分割

Object
Detection

Instance
Segmentation



CAT



草地, 猫, 树, 天空



DOG, DOG, CAT



DOG, DOG, CAT

No spatial extent


没有目标, 针对像素

多个目标

区域分割

将图像划分为若干个连通的区域



不区分实例目标, 仅仅关注像素



语义分割

给图像中的每个像素标注一个类别

不区分实例目标, 仅仅关注像素, 同时确定像素类别



本章内容

- 8.1.分割定义
- 8.2.区域分割
- 8.3.语义分割
- 8.4.实例分割

区域分割定义

- 令集合 R 代表整个图像区域，对 R 的分割可看作将 R 分成若干个满足以下条件的非空子集（子区域） $R_1, R_2, R_3, \dots, R_n$:

$$(1) \bigcup_{i=1}^n R_i$$

(2) 对所有的 i 和 $j, i \neq j$, 有 $R_i \cap R_j = \phi$

(3) 对 $i = 1, 2, \dots, n$, 有 $P(R_i) = \text{true}$


(4) 对 $i \neq j$, 有 $P(R_i \cup R_j) = \text{false}$

(5) 对 $i = 1, 2, \dots, n$, R_i 是连通的区域

区域分割想法: 聚类

聚类

整张图像



提取邻
接像素




我们需要做的是定义相似准则进行像素合并.

区域分割

1. 阈值分割
2. 区域生长
3. 聚类
4. 分裂归并


分割-阈值分割

- 聚类：按灰度值相似




分割-阈值分割


灰度直方图
-确定阈值



分割-阈值分割



原图



$\theta=100$



$\theta=75$



$\theta=50$








$\theta=25$




$\theta=5$

分割-阈值分割




分割-阈值分割

- 1.按照色彩相似性
- 2.按照纹理相似性
- 3.按照深度相似性
- 4.按照运动相似性



分割-区域生长



- 区域生长:

根据预先定义的生长准则来把像素或子区域集成较大区域的处理方法

- 方法:

以一组“种子”点开始来形成生长区域，将那些预定义属性类似于种子的邻域像素附加到每个种子上（如指定的灰度级或颜色）。

分割-区域生长

- 一种准则

R 为当前点的 N -邻域, P 为邻域内一点, 强度为 y

$$\text{均值 } \bar{x} = \frac{1}{N} \sum_{(r,c) \in R} I(r, c)$$

$$\text{方差 } S^2 = \frac{1}{N} \sum_{(r,c) \in R} (I(r, c) - \bar{x})^2$$

分割-区域生长

- T统计量

$$T = \left(\frac{(N-1) * N (y - \bar{x})^2}{N+1 S^2} \right)^{1/2}$$


- 决策

根据统计量的分布进行决策

$\Pr(T \leq t)$ 则生长， 否则开始新的区域

分割-区域生长

- 纹理区域无法处理



分割-聚类

K 均值聚类

- K 个类别 $C_1, \dots, C_K$ 均值 $m_1, \dots, m_K$.

- 最小均方误差

$$D = \frac{1}{N} \sum_k \sum_{x_i \in C_k} \|x_i - m_k\|^2$$


- 所有可能的划分中, 选择使得 D 最小的划分.

K-Means聚类


输入：一系列 n 维向量点，类别 K

1. 令 ic (迭代次数) 为 1
2. 随机选择 K 个点初始化均值 $m_1(1), \dots, m_k(1)$.
3. 对每个点 x_i 计算 $D(x_i, m_k(ic)), k=1, \dots, K$
并根据最小距离确定 x_i 的类别 C_j .
4. ic 增加 1, 更新均值 $m_1(ic), \dots, m_k(ic)$.
5. 重复步骤3和4直到 $C_k(ic) = C_k(ic+1)$ 对所有的 k .

K-Means 聚类



K-Means 聚类



K-means 变化

- 不同的初始化方法
- 不同的停止准则
- 类别软判决

EM算法

K-Means

- 起始步骤:
 - 初始化 K 类别: $C_1, \dots, C_K$
类别中心 m_j
- 迭代步骤:
 - 估计类别中心
$$x_i \implies C(x_i)$$
 - 重新估计类别参数

$$m_j = \text{mean}\{x_i \mid x_i \in C_j\}$$

K-Means 举例


1. Select an image: 2. Select a processor: 3. Click

Options:
Init Method

640*480 (607,118): RGB(20,22,1)



Process done !

(228,26): RGB(255,170,0)



分割-分裂归并

- 分裂归并- 4叉树






分割-分裂归并

- 分裂合并准则：区域特征一致性的测度
- 分裂：

当图像中某个区域的特征不一致时就将该区域分裂成4个相等的子区域

- 合并：

当相邻的子区域满足一致性特征时则将它们合成一个大区域,直至所有区域不再满足分裂合并的条件为止



本章内容





- 8.1.分割定义
- 8.2.区域分割
- 8.3.语义分割
- 8.4.实例分割

语义分割想法: 滑动窗

提取块

使用CNN分类

整张图像



牛

牛

草地

Farabet et al, "Learning Hierarchical Features for Scene Labeling," TPAMI 2013





Pinheiro and Collobert, "Recurrent Convolutional Neural Networks for Scene Labeling", ICML 2014

语义分割想法: 滑动窗

提取块

使用CNN分类

整张图像



牛

牛


草地

问题: 非常不高效的! 没有重复利用重叠块之间的共享特征

Farabet et al, "Learning Hierarchical Features for Scene Labeling," TPAMI 2013
Pinheiro and Collobert, "Recurrent Convolutional Neural Networks for Scene Labeling", ICML 2014

语义分割: 全卷积网络

将网络设计为多个卷积层级联来一次实现所有像素预测!




损失函数: 每像素交叉熵

Long et al, "Fully convolutional networks for semantic segmentation", CVPR 2015

语义分割: 全卷积网络

将网络设计为多个卷积层级联来一次实现所有像素预测!




输入:
 $3 \times H \times W$

问题 #1: 有效的感受野是卷积
层数的线性函数: L 个 3×3 conv
层, 感受野是 $1 + 2L$

Long et al, "Fully convolutional networks for semantic segmentation", CVPR 2015

语义分割: 全卷积网络

将网络设计为多个卷积层级联来一次实现所有像素预测!



输入:
 $3 \times H \times W$


问题 #1: 有效的感受野是卷积层数的线性函数: L 个 3×3 conv 层, 感受野是 $1+2L$

问题 #2: 高分辨率图像卷积代价是高昂的! 回顾 ResNet 主干网络下采样方法

Long et al, "Fully convolutional networks for semantic segmentation", CVPR 2015

语义分割: 全卷积网络

将网络设计为多个卷积层级联, 中间带有下采样和上采样!



Long, Shelhamer, and Darrell, "Fully Convolutional Networks for Semantic Segmentation", CVPR 2015
Noh et al, "Learning Deconvolution Network for Semantic Segmentation", ICCV 2015

语义分割: 全卷积网络


下采样:
池化, 带步长卷积

将网络设计为多个卷积层级联, 中间带有下采样和上采样!

上采样:
???



输入:
 $3 \times H \times W$



预测:
 $H \times W$

Long, Shelhamer, and Darrell, "Fully Convolutional Networks for Semantic Segmentation", CVPR 2015
Noh et al, "Learning Deconvolution Network for Semantic Segmentation", ICCV 2015

网络内部上采样: “上池化”

直接补零

1	2
3	4




1	0	2	0
0	0	0	0
3	0	4	0
0	0	0	0

输入
 $C \times 2 \times 2$

输出
 $C \times 4 \times 4$

网络内部上采样: “上池化”


直接补零



输入
 $C \times 2 \times 2$

输出
 $C \times 4 \times 4$


最近邻



输入
 $C \times 2 \times 2$

输出
 $C \times 4 \times 4$

网络内部上采样: 双线性插值



1.0 0	1.2 5	1.7 5	2.0 0
1.5 0	1.7 5	2.2 5	2.5 0
2.5 0	2.7 5	3.2 5	3.5 0
3.0 0	3.2 5	3.7 5	4.0 0


输入: $C \times 2 \times 2$

输出: $C \times 4 \times 4$

$$f_{x,y} = \sum_{i,j} f_{i,j} \max(0, 1 - |x - i|) \max(0, 1 - |y - j|) \quad i \in \{\lfloor x \rfloor - 1, \dots, \lceil x \rceil + 1\}$$
$$j \in \{\lfloor y \rfloor - 1, \dots, \lceil y \rceil + 1\}$$

使用x和y方向两个最近邻的点去线性近似

网络内部上采样: 二次样条插值



输入: $C \times 2 \times 2$

输出: $C \times 4 \times 4$

使用x和y方向三个最近邻的点三次样条近似

网络内部上采样: “最大上采样”

最大池化: 记住哪个位置存在最大值

1	2	6	3
3	5	2	1
1	2	2	1
7	3	4	8



5	6
7	8



剩余网络




1	2
3	4



0	0	2	0
0	1	0	0
0	0	0	0
3	0	0	4

最大上池化: 放到被记住的位置




每个下采样层和一个上采样层组成一对


Noh et al, “Learning Deconvolution Network for Semantic Segmentation”, ICCV 2015

可学习的上采样:转置卷积

回顾: 归一化 3×3 卷积, 步长 1, 填充 1




输入: 4×4



输出: 4×4


可学习的上采样:转置卷积

回顾: 归一化 3×3 卷积, 步长 1, 填充 1



可学习的上采样:转置卷积


回顾: 归一化 3×3 卷积, 步长 1, 填充 1



输入: 4×4




输入和滤波核
点乘




输出: 4×4

可学习的上采样:转置卷积

回顾: 归一化 3×3 卷积, 步长 2, 填充 1




输入: 4×4



输出: 2×2


可学习的上采样:转置卷积

回顾: 归一化 3×3 卷积, 步长 1, 填充 1



可学习的上采样:转置卷积


回顾: 归一化 3×3 卷积, 步长 2, 填充 1



输入: 4×4




输入和滤波核
点乘



输出: 2×2

可学习的上采样:转置卷积

回顾: 归一化 3×3 卷积, 步长 1, 填充 1




输入: 4×4

步长 > 1 卷积是 “可学习下采样”

我们能使用步长 < 1 用于 “可学习上采样” 吗?




输入和滤波核
点乘




输出: 2×2

可学习的上采样:转置卷积

3 x 3转置卷积, 步长 2




输入: 2 x 2



输出: 4 x 4

可学习的上采样:转置卷积


3 x 3转置卷积, 步长 2



输入: 2 x 2



输入值加权求和
复制到输出




输出: 4 x 4

可学习的上采样:转置卷积

3 x 3转置卷积, 步长 2


对每个输入像素的输出滤波器
移动2个像素



输入: 2 x 2



输入值加权求和
复制到输出




输出: 4 x 4

可学习的上采样:转置卷积

3 x 3转置卷积, 步长 2


对每个输入像素的输出滤波器移动2个像素



输入: 2 x 2



输入值加权求和
复制到输出




输出: 4 x 4

可学习的上采样:转置卷积

3 x 3转置卷积, 步长 2


输出为5x5 大小 – 需要在顶部和左边弃掉一个像素得到4x4大小输出




输入: 2 x 2



输入值加权求和
复制到输出



转置卷积: 1D 举例




转置卷积: 1D 举例

输入

滤波

输出



这个有很多名字:

- 反卷积 (不好)!
- 上卷积
- 分数步长卷积
- 后向步长卷积
- 转置卷积
(最佳名称)

卷积作为矩阵乘法(1D 举例)

可以使用矩阵乘法表示卷积

$$\vec{x} * \vec{a} = X\vec{a}$$

$$\begin{bmatrix} x & y & x & 0 & 0 & 0 \\ 0 & x & y & x & 0 & 0 \\ 0 & 0 & x & y & x & 0 \\ 0 & 0 & 0 & x & y & x \end{bmatrix} \begin{bmatrix} 0 \\ a \\ b \\ c \\ d \\ 0 \end{bmatrix} = \begin{bmatrix} ay + bz \\ ax + by + cz \\ bx + cy + dz \\ cx + dy \end{bmatrix}$$

举例: 1D conv, 内核大小=3,
步长=1, 填充=1

卷积作为矩阵乘法(1D 举例)

可以使用矩阵乘法表示卷积

转置卷积乘以相同矩阵的转置:

$$\vec{x} * \vec{a} = X\vec{a}$$

$$\begin{bmatrix} x & y & x & 0 & 0 & 0 \\ 0 & x & y & x & 0 & 0 \\ 0 & 0 & x & y & x & 0 \\ 0 & 0 & 0 & x & y & x \end{bmatrix} \begin{bmatrix} 0 \\ a \\ b \\ c \\ d \\ 0 \end{bmatrix} = \begin{bmatrix} ay + bz \\ ax + by + cz \\ bx + cy + dz \\ cx + dy \end{bmatrix}$$

$$\vec{x} *^T \vec{a} = X^T \vec{a}$$

$$\begin{bmatrix} x & 0 & 0 & 0 \\ y & x & 0 & 0 \\ z & y & x & 0 \\ 0 & z & y & x \\ 0 & 0 & z & y \\ 0 & 0 & 0 & z \end{bmatrix} \begin{bmatrix} a \\ b \\ c \\ d \end{bmatrix} = \begin{bmatrix} ax \\ ay + bx \\ az + by + cx \\ bz + cy + dx \\ cz + dy \\ dz \end{bmatrix}$$

举例: 1D conv, 内核大小=3, 当步长=1, 转置conv 为一个规则的conv
步长=1, 填充=1 (使用不同填充规则)

卷积作为矩阵乘法(1D 举例)

可以使用矩阵乘法表示卷积

转置卷积乘以相同矩阵的转置:

$$\vec{x} * \vec{a} = X \vec{a}$$

$$\vec{x} *^T \vec{a} = X^T \vec{a}$$

$$\begin{bmatrix} x & y & x & 0 & 0 & 0 \\ 0 & 0 & x & y & x & 0 \end{bmatrix} \begin{bmatrix} 0 \\ a \\ b \\ c \\ d \\ 0 \end{bmatrix} = \begin{bmatrix} ay + bz \\ bx + cy + dz \end{bmatrix}$$

举例: 1D conv, 内核大小=3,
步长=1, 填充=1

卷积作为矩阵乘法(1D 举例)

可以使用矩阵乘法表示卷积

$$\vec{x} * \vec{a} = X\vec{a}$$

$$\begin{bmatrix} x & y & x & 0 & 0 & 0 \\ 0 & 0 & x & y & x & 0 \end{bmatrix} \begin{bmatrix} 0 \\ a \\ b \\ c \\ d \\ 0 \end{bmatrix} = \begin{bmatrix} ay + bz \\ bx + cy + dz \end{bmatrix}$$

举例: 1D conv, 内核大小=3,
步长=1, 填充=1

转置卷积乘以相同矩阵的转置:

$$\vec{x} *^T \vec{a} = X^T \vec{a}$$

$$\begin{bmatrix} x & 0 \\ y & 0 \\ z & x \\ 0 & y \\ 0 & z \\ 0 & 0 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} ax \\ ay \\ az + bx \\ by \\ bz \\ 0 \end{bmatrix}$$


当步长>1, 转置卷积不能被表示为正常的conv

语义分割: 全卷积网络


下采样:
池化, 带步长卷积

设计网络为若干卷积层的级联, 网络中带有上采样和下采样处理!

上采样:
插值, 转置conv



输入:
 $3 \times H \times W$



预测:
 $H \times W$

损失函数: 每像素交叉熵

Long, Shelhamer, and Darrell, "Fully Convolutional Networks for Semantic Segmentation", CVPR 2015
Noh et al, "Learning Deconvolution Network for Semantic Segmentation", ICCV 2015

U-Nets

- 在编码和译码步骤跳跃连接
- 在图像降噪，绘制，光流和立体视觉中广泛应用




Figure 5.41 (a) The deconvolution network of Noh, Hong, and Han (2015) © 2015 IEEE and (b–c) the U-Net of Ronneberger, Fischer, and Brox (2015), redrawn using the PlotNeuralNet LaTeX package by Matt Dietke. In addition to the fine-to-coarse-to-fine bottleneck used in (a), the U-Net also has skip connections between encoding and decoding layers at the same resolution.



本章内容

- 8.1.分割定义
- 8.2.区域分割
- 8.3.语义分割
- 8.4.实例分割

事件与东西

事件: 目标类别能够分离
为具体实例 (e.g. 猫, 卡车,
人)

东西: 目标类别不能分离
为实例
(e.g. 天空, 草地, 水, 树)




计算机视觉任务

目标检测: 检测各个目标实例, 但
仅仅检测出边框
(仅仅事件!)



语义分割: 给出每个像素的类别,
同时确定各个实例和类别的连通
区域(既有事件也有东西)



计算机视觉任务: 实例分割


Classification



CAT

No spatial extent

Semantic Segmentation



GRASS, CAT, TREE,
SKY

没有目标, 像素级

Object Detection



DOG, DOG, CAT

多个目标


实例分割



DOG, DOG, CAT

计算机视觉任务: 实例分割

实例分割: 检测图像中的所有目标, 同时确定目标区域的所有像素 (仅仅事件)




[This image is CC0 public domain](#)

计算机视觉任务: 实例分割


实例分割: 检测图像中的所有目标, 同时确定目标区域的所有像素 (仅仅事件)

方法: 进行目标检测, 然后预测每个目标的分割区域掩膜




[This image is CC0 public domain](#)

目标检测: Faster R-CNN




Ren et al, "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks", NeurIPS 2015

实例分割: Mask R-CNN




He et al, "Mask R-CNN", ICCV 2017

Mask R-CNN




He et al, "Mask R-CNN", ICCV 2017


Mask R-CNN: 示例训练目标




Mask R-CNN:示例训练目标



Mask R-CNN:示例训练目标



Mask R-CNN:示例训练目标






The Generalized R-CNN
Framework for Object Detection

ICCV 2019 Tutorial
Visual Recognition for Images, Video, and 3D
Ross Girshick


facebook Artificial Intelligence Research

实例分割之外的任务

实例分割: 分离目标实例, 但仅仅提取目标




语义分割: 同时识别目标和背景, 但不分割实例



实例分割之外的任务: 全景分割

标注图像中的所有像素 (既有目标也有背景)

对于“背景”类别也分割出各个实例



Kirillov et al, "Panoptic Segmentation", CVPR 2019
Kirillov et al, "Panoptic Feature Pyramid Networks", CVPR 2019

实例分割之外的任务: 全景分割



Kirillov et al, "Panoptic Feature Pyramid Networks", CVPR 2019

实例分割之外的任务: 人的关键点检测

将人的姿态表示为一些关键点的集合


e.g. 17 关键点:

- 鼻子
- Left / Right 眼睛
- Left / Right 耳朵
- Left / Right 肩膀
- Left / Right 肘部
- Left / Right 腕部
- Left / Right 臀部
- Left / Right 膝盖
- Left / Right 踝关节



[Person image is CC0 public domain](#)

Mask R-CNN: 实例分割



Object
Detection

Instance
Segmentation

Keypoint
estimation



DOG, DOG, CAT




DOG, DOG, CAT




He et al, "Mask R-CNN", ICCV 2017

Mask R-CNN: 关键点估计





He et al, "Mask R-CNN", ICCV 2017

Mask R-CNN: 关键点



He et al, "Mask R-CNN", ICCV 2017




联合实例分割和姿态估计



He et al, "Mask R-CNN", ICCV 2017

总结

- 语义分割
- 实例分割



结束

下一次课

- 图像生成