



软件架构设计

主讲：李伟刚

liweigang@nwpu.edu.cn

西北工业大学软件学院



第十四章 智能体与大模型应用架构实践

主要内容

- 1 大模型应用技术介绍
- 2 智能体应用技术介绍
- 3 应用架构案例与探索



1.1 基于大模型AI能力深度分析

● 大模型的感知能力



问题



解答



o1 qwen-vl-max



方顺-电子保单.pdf
文件 199.1 KB

这份保单有哪些对投保人不利的条款?

+ 代码解释器

Open WebUI - v0.5.10



方顺-电子保单.pdf
文件 199.1 KB

这份保单有哪些对投保人不利的条款?

o1 qwen-vl-max

这份保单中对投保人不利的条款包括:

1. 如果投保人未按照约定时间足额交付当期保费, 并且在保险合同约定的交费延长期内仍未补交, 保险合同的保险期间将在上一交费周期结束时终止。对于保险期间终止后发生的保险事故, 保险人不承担保险责任。
2. 如被保险人在保险期间内出险, 需在48小时内报案。如果超出48小时报案导致保险人无法核实真实情况, 保险人有权拒赔。

1 方顺-电子保单.pdf



西北工业大学

NORTHWESTERN POLYTECHNICAL UNIVERSITY




1.1 基于大模型AI能力深度分析

● 大模型的感知能力




1.1 基于大模型AI能力深度分析

● 大模型的理解能力



1.1 基于大模型AI能力深度分析

● 大模型的理解能力



西北工业大学

NORTHWESTERN POLYTECHNICAL UNIVERSITY

1.1 基于大模型AI能力深度分析

● 大模型的输出能力



文本

文章和故事创作

- 新闻报道
- 小说和短篇故事
- 诗歌和歌词

技术文档和说明

- 用户手册
- 技术指南
- API 文档

教育和培训材料

- 教科书章节
- 练习题和答案
- 在线课程内容

市场营销

- 广告文案
- 社交媒体帖子
- 市场分析报告

法律和法规

- 合同草案
- 法律意见书
- 合规指南

医疗和健康

- 医学研究报告
- 健康建议和指南
- 病例分析

客服和支持

- 自动回复邮件
- FAQ (常见问题解答)
- 客户支持对话



1.1 基于大模型AI能力深度分析

- 大模型的输出能力
 - 面向机器阅读与协作



1.2 对话与推理模型介绍

- 重点开源对话模型

- Qwen/Qwen2.5

- 0.5B、1.5B、3B、7B、14B、32B、72B

- Deepseek/Deepseek-V3

- 671B

- Meta-Llama/Llama3.x

- 1B、3B、8B、70B、405B

- 重点开源推理模型

- Deepseek/Deepseek-R1

- 671B、Distill-Qwen(1.5B、7B、14B、32B)、 Distill-Llama-(8B、70B)

- Qwen/QWQ

- 32B

- 总体上模型参数越大，模型智力会表现得越强

- 不同之处：Deepseek-V3属于MoE混合专家模型而非传统的稠密模型。由多个子模型组成，加上路由机制，每次只激活一小部分专家网络，所以MoE模型参数规模会很大。



1.2 对话与推理模型介绍

- 对话模型应用场景

- 智能客服系统
- 内容创作与生成
- 数字机器人互动
- 嵌入生产指令环节

对话模型适合实时交互性要求高的应用场景。

- 推理模型应用场景


- 解决复杂数学问题
- 刑侦、问诊等垂直领域的推理研判
- 编程设计、数据分析、科学研究等领域分析助手。

推理模型适合复杂任务深入理解分析的应用场景。



1.2 对话与推理模型介绍

- 对话模型与推理模型的结合案例
 - 教育辅导大模型服务可以通过对话模型与学生交流和理解问题。
 - 通过思维链模型提取解题思路、优化并辅导学生解题。



- 如何理解图呢？




1.3 图形多模态模型介绍

- 面向视觉理解的开源多模态模型
 - THUDM/Cogvlm2-llama3、THUDM/Cogvlm2-video-llama3
 - Cogvlm2-llama3 19B, Cogvlm2-video-llama3 12B
 - Qwen/Qwen2.5-vl
 - 3B、7B、32B、72B
 - MetaLlama/llama3.2-vision
 - 11B、90B
- 面向文档理解的开源多模态模型底座
 - Florence2 0.77B、BLIP2 2.7B
 - OmniParser面向视觉GUI理解的智能体。
 - GOT-OCR2 0.77B、Qwen2-VL-OCR 2B
 - 专门针对OCR任务优化的小参数规模视觉模型。



1.3 图形多模态模型介绍



图像目标理解

多图态势对比

OmniParser软件界面元素捕获

RPA（机器人流程自动化）的基础



西北工业大学

NORTHWESTERN POLYTECHNICAL UNIVERSITY

1.4 语音模型介绍

- 语音识别、理解开源模型

- OpenAI/Whisper系列 最大1.5B
- FunAudioLLM/SenseVoice系列 最大1.5B
- Qwen/Qwen2-audio 7B

- 语音生成、合成开源模型

- FunAudioLLM/CosyVoice 最大0.5B
- 2Noise/ChatTTS
- MyShell-Ai/MeloTTS 、 SparkAudio/Spark-TTS

- 端到端实时语音对话开源模型

- THUDM/glm-4-voice 9b
- gpt-omni/mini-omni

语音识别
情感感知
对话模型整合


情感/音色
实时交互
语音合成

Audio-Audio对话模型整合




1.4 语音模型介绍

● 语音对话流程



最常见语大模型语音架构




实时性播放优化




1.4 语音模型介绍

● 语音对话模型融合



LLM模型直接支持语音理解和文字输出



LLM模型直接支持语音理解和语音输出

点对点模型非常适合边缘侧应用场景





1.4 语音模型介绍

- 语音对话示例

云对话模式: SenseVoice->Qwen2.5->CosyVoice

点对点模式: GLM4-Voice-9B




西北工业大学



NORTHWESTERN POLYTECHNICAL UNIVERSITY

1.5 本地部署与访问

● 大模型访问方式



大模型由MaaS服务商托管或使用API



完全的大模型私有化本地部署




西北工业大学

NORTHWESTERN POLYTECHNICAL UNIVERSITY

1.5 本地部署与访问

● X inference为例的本地化部署架构



Transformers、vLLM、SGLang、Llama.cpp, 选择部署LLM的推理引擎。


通过代理服务平台实现多种模型的模型下载、模型加载、算力分配、服务运行。

代理服务可以通过OpenAI API(事实上的通用标准接口)对外提供模型访问服务。



1.5 本地部署与访问


● Xinference为例的本地化部署架构




2.1 智能体应用技术介绍

- 智能体的技术发展

AI workflow人工编排



发展趋势



- AI工作流和智能体有哪些技术应用平台或框架呢?

基于大模型智力的智能体任务驱动




西北工业大学

NORTHWESTERN POLYTECHNICAL UNIVERSITY

2.2 Dify AI workflows 开发平台

● Dify workflows 架构

- 基于传统 workflow 路线编排
- 每个流程环节赋予各种动作
 - 大模型提示词编排调用
 - **Python**脚本运行任务
 - 外部服务工具调用
 - 知识库查询
- 流程环节之间具有数据记忆



2.2 Dify AI workflows开发平台

● Dify workflows应用示例



2.2 Dify AI workflows开发平台

Dify workflows应用示例

Test Run#11

输入 结果 详情 追踪

开始

71.973 ms

输入

1 {

2 "URL": "https://medium.com/artificial-corner/how-google-quietly-took-the-lead-in-the-ai-race-with-gemini-2-5-c98dfb58b6a1",

3 "sys.files": [],

4 "sys.user_id": "67975cfd-99fb-407d-ba94-71edd8a99035",

5 "sys.app_id":

输出

1 {

2 "text": "the Lead i

3 5\nAUTHORS

4 None\nTOP

5 ResultsSom

6 time - it


7 failed lau

8 to downla

科技新闻搬运工作可以由AI完成

How Google Quietly Took the Lead in the AI Race with Gemini 2.5

The PyCoach · Follow
Published in Artificial Corner · 6 min read · 3 days ago



Something feels different this time — it doesn't seem like just another failed launch from Google. I don't want to downplay the past efforts of the DeepMind team, but the truth is, they didn't always meet user expectations.

Just a few weeks ago, Google released Gemini 2.5 Pro, and the internet lit up. Maybe not quite as explosively as with DeepSeek or GPT-4o, but still, I have to admit that ever since Google launched DeepResearch, the updates that have followed have been impressive — definitely worth noting.

In a lot of my early tests using prompts, the results were surprisingly strong. Naturally, it was hard not to compare it to other AIs out there.

One example that really stood out to me came from a hospital in Japan, where the same AI technology was used to transcribe and summarize doctors' notes, cutting down nurses' paperwork time by 42% and helping to ease their stress.

Test Run#11

输入 结果 详情 追踪

技术解读报告

71.973 ms

主题

2.659 s

Gemini 2.5 如何让谷歌在 AI 竞赛中悄然领先

975 tokens · 32,097 s

1.194K tokens · 26,224 s

报告

1. 引言

谷歌在人工智能领域的竞争中一直保持着低调，但近期发布的 Gemini 2.5 Pro 版本却引发了广泛关注。尽管没有像 DeepSeek 或 GPT-4 那样引起巨大的轰动，Gemini 2.5 Pro 的表现依然令人印象深刻。本文将探讨 Gemini 2.5 Pro 的技术特点及其在实际应用中的表现，分析其是否能够在 AI 竞赛中脱颖而出。

2. 技术背景

DeepMind 团队的努力: 尽管 DeepMind 团队在过去的努力中取得了一些成果，但这些成果并不总是符合用户的期望。

Gemini 2.5 Pro 的发布: 几周前，谷歌发布了 Gemini 2.5 Pro，引起了互联网上的广泛讨论。这一版本的发布标志着谷歌在 AI 领域的最新进展。

3. 技术特点

强大的性能: 早期的测试结果显示，Gemini 2.5 Pro 在处理复杂任务时表现出色。例如，它能够解决博士级别的科学和数学问题，这是之前模型难以实现的。

实际应用案例: 在日本的一家医院中，Gemini 2.5 Pro 被用于转录和总结医生的笔记，成功减少了护士 42% 的文书工作时间，显著缓解了他们的压力。

多任务处理能力: Gemini 2.5 Pro 不仅能够处理复杂的学术问题，还能在日常生活中发挥重要作用，如撰写邮件和推荐餐厅。

4. 与竞争对手的比较

超越 GPT-4 和 Claude: Gemini 2.5 Pro 的独特之处在于其强大的推理能力和多模态支持，使其在 AI 竞赛中独树一帜。



2.3 MetaGPT多智能体框架


- 智能体定义:智能体、记忆、工具、规划、行动

- 记忆、工具、行动:

- 行动、工具: 行动根据规划的决定, 工具用于行动的执行。
 - 记忆: 当前任务的短期记忆, 知识库的持久记忆。

- 规划:

- 思维链与子目标分解: 宏观的子目标分解, 微观的思维链。
 - 反思与自我批评: 反思就是分析过去, 自我批评就是评估改进。



2.3 MetaGPT多智能体框架

● MetaGPT算法工程师智能体示例

```
C:\Users\fangs\ai\metagpt\examples\machine_learning2.py
2025-04-17 16:24:34.115 | INFO      | metagpt.const:get_metagpt_package_root:29 -
Package root set to C:\Users\fangs\ai\metagpt\examples
```json
```

## 任务1.数据集加载

## 任务1.数据集加载

```
[
 {
 "task_id": "1",
 "dependent_task_ids": [],
 "instruction": "Load the dataset and perform exploratory data analysis, including checking for missing values, understanding the distribution of sales, and identifying any outliers.",
 "task type": "eda"
 }
]
```

## 任务2：数据集预处理

```
"task_id": "2",
"dependent_task_ids": ["1"],
"instruction": "Preprocess the dataset by splitting it into training and validation sets (last 40 weeks for validation). Also, encode categorical variables if necessary and handle any missing values.",
"task type": "data preprocessing"
```

### 任务3：训练、预测和打印

```

 "task_id": "3",
 "dependent_task_ids": ["2"],
 "instruction": "Train a model to predict sales for each department in every store using the training dataset. Print key variables such as model parameters and training metrics.",
 "task_type": "model train"
 }
}

```

]

## 川练、预内代码生

训练数据  
为  
多信息用于

split the  
l sales  
is

```
2025-04-17 16:24:48.870 | INFO | metagpt.roles.di.
data_interpreter:_write_code:149 - ready to WriteAnalysisCode
```python  
import pandas as pd  
import numpy as np  
import matplotlib.pyplot as plt  
import seaborn as sns
```

```
# Load the dataset
file_path = r'C:\Users\fangs\ai\metagpt\examples\train.csv'
df = pd.read_csv(file_path)
```

```
# Display the first few rows of the dataframe
print(df.head())
```

```
# Check for missing values
print(df.isnull().sum())
```

```
# Understand the distribution of sales
sales_distribution = df['Weekly_Sales'].describe()
print(sales_distribution)
```

```
# Identify outliers in sales
Q1 = df['Weekly_Sales'].quantile(0.25)
Q3 = df['Weekly_Sales'].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR
outliers = df[(df['Weekly_Sales'] < lower_bound) | (df['Weekly_Sales'] > upper_bound)]
print(f"Number of outliers: {len(outliers)}")
```

```
# Plot the distribution of sales
plt.figure(figsize=(10, 6))
sns.histplot(df['Weekly_Sales'], kde=True)
plt.title('Distribution of Weekly Sales')
plt.xlabel('Weekly Sales')
plt.ylabel('Frequency')
plt.show()
```

```
# Correlation matrix
numeric_df = df.select_dtypes(include=[np.number])
correlation_matrix = numeric_df.corr()
plt.figure(figsize=(12, 8))
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm')
plt.title('Correlation Matrix')
plt.show()
```

读取本地train.csv数据文件

任务1代码生成效果


[illegible]

西北工業大學

NORTHWESTERN POLYTECHNICAL UNIVERSITY

2.3 MetaGPT多智能体框架

MetaGPT算法工程师智能体示例



算法代码生成
算法代码执行
代码调试优化

```
2025-04-17 16:25:20.781 | INFO | metagpt.roles.di.data_interpreter:_write_code:149 - ready to WriteAnalysisCode
```python
from xgboost import XGBRegressor
from sklearn.metrics import mean_absolute_error
from sklearn.model_selection import GridSearchCV

Define the model
model = XGBRegressor(objective='reg:squarederror', n_jobs=-1)

Define the parameter grid for hyperparameter tuning
param_grid = {
 'n_estimators': [100, 200, 300],
 'max_depth': [3, 5, 7],
 'learning_rate': [0.01, 0.1, 0.2]
}

Perform grid search to find the best hyperparameters
grid_search = GridSearchCV(estimator=model, param_grid=param_grid, cv=3, scoring='neg_mean_absolute_error', n_jobs=-1)
grid_search.fit(train_df.drop(columns=['Weekly_Sales', 'Date']), train_df[['Weekly_Sales']])

Print the best parameters and the best score
print("Best parameters found: ", grid_search.best_params_)
print("Best score found: ", -grid_search.best_score_)

Train the model with the best parameters
best_model = grid_search.best_estimator_
best_model.fit(train_df.drop(columns=['Weekly_Sales', 'Date']), train_df[['Weekly_Sales']])

Make predictions on the validation set
val_predictions = best_model.predict(val_df.drop(columns=['Weekly_Sales', 'Date']))

Calculate the weighted mean absolute error (WMAE)
weights = val_df['Weekly_Sales'].abs().sum()
wmae = mean_absolute_error(val_df['Weekly_Sales'], val_predictions, sample_weight=val_df['Weekly_Sales']) / weights
print(f'Weighted Mean Absolute Error (WMAE): {wmae}')

Plot the total sales trends
plt.figure(figsize=(14, 7))
plt.plot(train_df.groupby('Date')['Weekly_Sales'].sum(), label='Training Data')
plt.plot(val_df.groupby('Date')['Weekly_Sales'].sum(), label='Validation Data')
plt.title('Total Sales Trends Over Time')
plt.xlabel('Date')
plt.ylabel('Total Weekly Sales')
plt.legend()
plt.show()

Plot scatter plots of ground truth and predictions on validation data
plt.figure(figsize=(10, 6))
plt.scatter(val_df['Weekly_Sales'], val_predictions, alpha=0.5)
plt.plot([min(val_df['Weekly_Sales']), max(val_df['Weekly_Sales'])], [min(val_df['Weekly_Sales']), max(val_df['Weekly_Sales'])], color='red', linestyle='--')
plt.title('Ground Truth vs Predictions')
plt.xlabel('Ground Truth')
plt.ylabel('Predictions')
plt.show()
```

任务3代码生成效果

模型训练

验证集预测

绘制真实值与预测值散点图



西北工业大学

NORTHWESTERN POLYTECHNICAL UNIVERSITY

## 2.3 MetaGPT多智能体框架

- 软件项目开发多智能体应用

- 多智能体角色

- 需求分析智能体
    - 架构设计智能体
    - 前端开发智能体
    - 后端开发智能体
    - 数据库开发智能体
    - 测试智能体
    - 文档智能体
    - 项目管理智能体

- 经济系统

- 成功解决关键bug的智能体获得更高"声誉分"
    - "声誉分"影响路由决策，表现好的智能体获得更多重要任务

- 路由

- UI问题路由给前端开发智能体
    - 数据库查询问题路由给数据库开发智能体

- 订阅

- 测试智能体订阅代码变更事件，自动触发相关测试
    - 文档智能体订阅API变更事件，自动更新API文档

- 评审

- 评估生成代码的质量和性能
    - 评估需求分析的准确性和完整性

# 3.1 机器人巡检智能体应用架构案例

## 园区机器人场景分类



机器人类型集合



楼宇清洁机器人



配送送物机器人



大堂迎宾讲解机器人



安保巡检机器人



自动售货柜机器人



送餐机器人



园区巡检机器人

## 重点关注巡检机器人




西北工业大学

NORTHWESTERN POLYTECHNICAL UNIVERSITY

# 3.1 机器人巡检智能体应用架构案例

## ● 园区巡检机器人的目标识别




西北工业大学

NORTHWESTERN POLYTECHNICAL UNIVERSITY

# 3.1 机器人巡检智能体应用架构案例

## ● 机器人巡检云边一体架构

- 边缘侧负责识别与行动
- 云脑端负责规划与决策




- 云脑智能体由模型集、知识图谱、专家知识库、工具集组成，统一由智能体规划与决策中心连接与调度。



# 3.1 机器人巡检智能体应用架构案例

## ● 机器人巡检智能体通讯关系架构

- 园区路径规划基于实景构建
- 实景三维形成空间知识图谱
- 空间图谱用于行动规划与轨迹预测
- 智能体的内核采用**AI**工作流编排
- 边缘侧与内核之间通过云端调度
- 云端调度与边缘侧进行指令协作
- 内核与工具集连接进行各项决策
- 边缘侧上传关键音视频与目标定位数据
- 云脑下发决策指令实现用户端提醒
- 云脑下发路线规划指挥机器人行动



# 3.1 机器人巡检智能体应用架构案例

- 机器人巡检实景三维构建



- 前期无人机拍摄
- 三维重建技术实景重建
- 为用户提供展示入口
- 用户可基于**3D**场景监视
- 机器人定位展示
- 路线规划展示

- 基于三维场景的标注
- 基于标注的知识图谱



# 3.1 机器人巡检智能体应用架构案例

## 实景标注与合成空间知识图谱



Node properties

point

<elementId>	4:1801d9b7-3d21-48f7-a280-3a78b95ce14f:222
<id>	222
ID	48f3b67c
area	西电创新港
lati	34.255501
longi	108.655919
name	同和苑北路起点西



西北工业大学

NORTHWESTERN POLYTECHNICAL UNIVERSITY

# 3.1 机器人巡检智能体应用架构案例

## ● 基于视觉多模态的火情态势分析

运用多模态大模型在场景解释和连续对比方面的优势



{  
"火势等级": "轻度",  
"火源位置": "街道中间",  
"烟雾状况": "轻度",  
"火势蔓延速度": "缓慢",  
"周围环境": "商业区",  
"附近设施": "商店和餐馆"  
}



{  
"火势等级": "重度",  
"火势等级与图一的对比": "较重",  
"火源位置": "街道中间",  
"火源位置与图一的对比": "相似",  
"烟雾状况": "浓烟",  
"烟雾状况与图一的对比": "相似",  
"火势蔓延速度": "快速",  
"火势蔓延速度与图一的对比": "快于图一",  
"火势蔓延状况": "持续扩散",  
"周围环境": "城市街道",  
"周围环境与图一的对比": "相似",  
"附近设施": "商店",  
"附近设施与图一的对比": "相似"  
}




西北工业大学

NORTHWESTERN POLYTECHNICAL UNIVERSITY

# 3.1 机器人巡检智能体应用架构案例

## ● 云脑规划与决策内核——AI workflow





## 3.1 机器人巡检智能体应用架构案例

- 机器人巡检实验过程演示



## 3.2 面向政务服务知识库的架构设计探索

### ● 本地文档的大模型结合



OI deepseek-r1

基于《国务院关于印发新一代人工智能发展规划的通知》内容，结合行政单位职能特性，梳理核心要点及执行建议如下：

#### 一、核心政策要点

##### 1. 战略定位

人工智能发展上升至国家战略层面，要求形成“基础研究-技术攻关-产业应用”全链条创新体系，重点突破芯片、算法等“卡脖子”领域。国务院关于印发新一代人工智能发展规划的通知.pdf。

##### 2. 阶段目标

- 2020年：构建基础技术体系，培育经济增长点
- 2025年：实现重大原创突破，形成国际竞争力
- 2030年：建成世界主要人工智能创新中心 国务院关于印发新一代人工智能发展规划的通知.pdf

##### 3. 资源配置机制

建立“财政引导+市场主导”双轮驱动模式，统筹政府投资基金与社会资本，重点支持技术研发与成果转化

国务院关于印发新一代人工智能发展规划的通知.pdf。

#### 二、战略规划建议

##### 1. 审批机制创新

- 设立AI项目“绿色通道”，对涉及基础算法研究、民生应用项目实行优先审批
- 建立动态清单管理制度，定期更新重点支持领域目录

##### 2. 资源整合策略

- 搭建政企研对接平台，推动审批数据与AI技术深度融合
- 探索“容缺受理+AI预审”模式，利用智能系统辅助形式审查

##### 3. 风险防控体系




西北工业大学

NORTHWESTERN POLYTECHNICAL UNIVERSITY

# 3.2 面向政务服务知识库的架构设计探索

## 本地文档



国务院关于印发新一代人工智能发展规划的通知.pdf

118 分段

分段-01 · 244 字符 · 0 召回次数

国务院关于印发  
新一代人工智能发展规划的通知...

#印发 #规划 #人工智能 #35 #发展 #新一代 #此件 #2017 #国务院 #抢抓

分段-02 · 236 字符 · 0 召回次数

一、战略态势

人工智能发展进入新阶段。经过 60 多年的演进，特别是在移动互联网、大...

#脑科学 #跨媒体 #驱动 #协同 #人工智能 #发展 #60 #人机 #智能 #自主

分段-03 · 203 字符 · 0 召回次数

当前，新一代人工智能相关学科发展、理论建模、技术创新、软

硬件升级等整体推进，正在引发链式突破，推动经济社会各领域从数字化、网络..

#链式 #国际竞争 #人工智能 #标准规范 #主导权 #化向 #智能化 #顶尖 #跃升 #建模

分段-04 · 123 字符 · 0 召回次数

当前，我国国家安全和国际竞争形势更加复

杂，必须放眼全球，把人工智能发展放在国家战略层面系统布局、主动谋划，牢..

#引擎 #放眼 #战略 #国际竞争 #人工智能 #主动 #发展 #国家 #安全 #谋划

分段-05 · 144 字符 · 0 召回次数

编辑分段

分段-01 · 244 字符

国务院关于印发  
新一代人工智能发展规划的通知  
国发〔2017〕35 号  
各省、自治区、直辖市人民政府，国务院各部委、各直属机构：  
现将《新一代人工智能发展规划》印发给你们，请认真贯彻执行。  
国务院  
2017 年 7 月 8 日  
(此件公开发布)  
新一代人工智能发展规划  
人工智能的迅速发展将深刻改变人类社会生活、改变世界。为抢抓人工智能  
发展的重大战略机遇，构筑我国人工智能发展的先发优势，加快建设创新型国家  
和世界科技强国，按照党中央、国务院部署要求，制定本规划

关键词


印发 × 规划 × 人工智能 × 35 × 发展 × 新一代 × 此件 × 2017 ×  
国务院 × 抢抓 × + 添加关键词

取消 ESC 保存 Ctrl S



## 3.2 面向政务服务知识库的架构设计探索

### ● 大模型与知识库的检索增强生成（RAG）机制



1. 原始内容被知识分段。
2. 知识基于向量进行相似性查询。
3. 根据相似性排序取前几条作为提示词。
4. 大模型结合知识库提示词生成答案

1. 大量重复的文档导致排序结果无效。
2. 大量关键词相似但内容没有关联的文档，导致提问与结果大相径庭。
3. 每次索引更新可能都导致用户查询出现严重不一致。



# 3.2 面向政务服务知识库的架构设计探索

## ● 面向政务大规模文档知识库的架构改进设计



架构模式  
可以应用  
在更多知  
识库场景




西北工业大学

NORTHWESTERN POLYTECHNICAL UNIVERSITY

## 3.2 面向政务服务知识库的架构设计探索


### ● 政务服务知识库应用场景架构探索

- 公众服务与知识库结合
- 打造公共服务知识库
- 打造知识库服务中心
- 政务应用服务与知识库结合



## 3.2 面向政务服务知识库的架构设计探索

### 政务服务知识库与大数据的结合





## 3.2 面向政务服务知识库的架构设计探索

### ● 面向政务大规模文档知识库查询架构设计

- 基于知识库路由调度的政务RAG查询流程
- 基于分层的知识库子库定位
- 基于相似性的知识向量检索
- 基于关联度的知识图谱追溯

- 多重检索机制的答案混合生成，查询结果持续性改进，满足海量文档知识化的查询有效性。



Five light purple circles are arranged in a pentagonal pattern around the text. Two circles are solid, and three are hollow outlines.

**THE END**